

Stage de recherche

Modélisation et prévision des prix spot électriques sur le marché néerlandais

Elaboré par :

Ahmed SAIDI

Encadré par :

Mme. Hanen MEZGHANI

Référent interne :

M. Francesco RUSSO

2^{ème} année TA

Majeure : mathématiques appliquées

Année universitaire : 2025/2026

Resumé

La prévision des prix spot de l'électricité constitue un enjeu important en raison de leur forte volatilité et de leurs variations extrêmes. Ce travail porte sur la modélisation et la prévision des prix spot sur le marché néerlandais. Plusieurs approches sont étudiées, notamment les modèles de Schwartz à un et deux facteurs, le filtre de Kalman ainsi que les modèles d'apprentissage automatique XGBoost et LSTM. Une approche hybride combinant la décomposition stochastique et les modèles d'apprentissage automatique est ensuite proposée. Les différentes méthodes sont comparées en termes de précision des prévisions et de qualité des intervalles de confiance. Les résultats montrent l'intérêt de l'approche hybride pour améliorer la prévision des prix de l'électricité.

Mots-clés : Prix de l'électricité, prévision, modèle de Schwartz, filtre de Kalman, XGBoost, LSTM, approche hybride

Abstract

Forecasting electricity spot prices is challenging due to their high volatility and extreme variations. This work focuses on modeling and forecasting electricity spot prices in the Dutch market. Several approaches are investigated, including one- and two-factor Schwartz models, the Kalman filter, and Machine Learning models such as XGBoost and LSTM. A hybrid approach combining stochastic decomposition with Machine Learning models is then proposed. The different methods are compared in terms of forecasting accuracy and confidence interval quality. The results highlight the potential of the hybrid approach for improving electricity price forecasting.

Key words : Electricity prices, forecasting, Schwartz model, Kalman filter, XGBoost, LSTM, hybrid approach

Remerciements

Je tiens à adresser mes sincères remerciements à toutes les personnes qui ont contribué à la réalisation de ce travail.

Je remercie tout particulièrement mon encadrante universitaire à la Faculté des Sciences de Tunis El Manar, Madame Hanen Mezghani, pour son encadrement, sa disponibilité et ses précieux conseils tout au long de ce travail. Ses orientations et son soutien m'ont permis de progresser et de mener ce projet dans les meilleures conditions. Je tiens également à remercier l'équipe du LAMSIN de l'ENIT pour son accueil et pour les conditions de travail qui m'ont été offertes durant mon stage.

À toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail, j'exprime ma profonde gratitude.

TABLE DES MATIÈRES

Table des figures	6
1 Théorie : modèles factoriels de Schwartz	10
1.1 Introduction	10
1.2 Modèle factoriel de Schwartz	10
1.2.1 Formulation du Modèle de Schwartz	10
1.2.2 Analyse du prix spot	12
1.2.3 La prime de risque	13
1.2.4 Le modèle par produit	14
1.2.5 Calibration des modèles	15
2 Contexte et analyse exploratoire des données	17
2.1 Le marché électrique spot néerlandais	17
2.1.1 Fonctionnement du marché Day-Ahead	17
2.1.2 Spécificités du marché électrique	17
2.2 Données utilisées	18
2.2.1 Source et description	18
2.2.2 Traitement des données	18
2.3 Analyse exploratoire des données	19
2.3.1 Vue d'ensemble de l'année 2025	19
2.3.2 Saisonnalité mensuelle et hebdomadaire	20
2.3.3 Saisonnalité intra-journalière	21
2.3.4 Distribution et dépendances temporelles	22
2.3.5 Analyse des prix négatifs	23
2.3.6 Synthèse	24

3	Modèle de Schwartz à un facteur	25
3.1	Rappel théorique	25
3.1.1	Modèle continu	25
3.1.2	Justification du cas désaisonnalisé (m constante)	25
3.2	Discrétisation et estimation	26
3.2.1	Modèle discret AR(1)	26
3.2.2	Estimation par MCO	27
3.2.3	Estimation par maximum de vraisemblance (EMV)	27
3.3	Simulation de validation	27
3.3.1	Protocole	27
3.3.2	Comparaison MCO vs EMV	28
3.3.3	Résultats de la simulation de validation	29
3.3.4	Tests des résidus simulés	29
3.4	Calibration sur données réelles	29
3.4.1	Données	29
3.4.2	Paramètres estimés	30
3.5	Tests des résidus réels	31
3.6	Prédiction et intervalles de confiance	32
3.6.1	Formule analytique	32
3.6.2	Validation Monte Carlo	32
3.6.3	Résultats sur l'ensemble d'entraînement	33
3.7	Modèle XGBoost	34
3.7.1	Principe et ingénierie des variables explicatives	34
3.7.2	Hyperparamètres	34
3.7.3	Intervalle de confiance par quantile regression	34
3.8	Modèle LSTM	37
3.8.1	Principe et justification de l'architecture	37
3.8.2	Validation empirique de la longueur de séquence	38
3.8.3	Architecture retenue	38
3.8.4	Intervalles de confiance par Monte Carlo <i>Dropout</i>	39
3.8.5	Résultats	39
3.9	Comparaison des modèles	40
3.9.1	Précision ponctuelle	40
3.9.2	Discussion	42
3.10	Conclusion	43
4	Modèle de Schwartz deux facteur	44
4.1	Motivation et décomposition du log-prix	44
4.2	Dynamiques continues	44
4.2.1	Origine du terme $-\frac{1}{2}\sigma_l^2 dt$	45
4.2.2	Reparamétrage de c_t	45

4.3	Représentation espace d'états	45
4.3.1	Problème des états cachés	45
4.3.2	Discrétisation exacte	46
4.3.3	Forme matricielle	46
4.4	Le filtre de Kalman	47
4.4.1	Principe général	47
4.4.2	Équations détaillées	47
4.4.3	Remarque sur la distinction données simulées/réelles	48
4.5	Simulation de validation	49
4.5.1	Protocole	49
4.5.2	Reconstruction des composantes	49
4.5.3	Résultats de calibration	50
4.6	Calibration sur données réelles	50
4.6.1	Paramètres estimés	50
4.6.2	Décomposition des facteurs filtrés	51
4.6.3	Décomposition de la variance	52
4.6.4	Indépendance empirique des composantes	53
4.6.5	Contribution aux pics de prix	54
4.6.6	Comparaison des résidus : un facteur vs deux facteurs	55
4.7	Approches hybrides	56
4.7.1	Principe et motivation	56
4.7.2	XGBoost hybride	57
4.7.3	LSTM hybride	58
4.7.4	Apport systématique de la décomposition Kalman	60
4.8	Conclusion	61
5	Discussion et comparaison finale	62
5.1	Métriques d'évaluation utilisées	62
5.1.1	Métriques de précision ponctuelle	62
5.1.2	Métriques de qualité des intervalles de confiance	63
5.2	Comparaison finale des modèles	63
5.2.1	Tableau récapitulatif	63
5.2.2	Analyse par critère	63
5.3	Extension aux données horaires	64
5.3.1	Motivation	64
5.3.2	Résultats	64
5.3.3	Discussion	64
5.3.4	Prédiction heure par heure	65
5.4	Limites du travail	65
	Bibliographie	69

TABLE DES FIGURES

2.1	Vue d'ensemble du marché électrique néerlandais en 2025.	19
2.2	Saisonnalité mensuelle et hebdomadaire	20
2.3	Saisonnalité intra-journalière.	21
2.4	Distribution et dépendances temporelles NL 2025.	22
2.5	Analyse des prix négatifs	23
3.1	Trajectoire simulée du log-prix X_t (processus d'Ornstein-Uhlenbeck	28
3.2	Visualisation les données 2024-2026.	30
3.3	Résidus MCO sur l'ensemble d'entraînement.	31
3.4	Prédiction du modèle de Schwartz et IC à 95% sur l'ensemble de test	33
3.5	Prédiction XGBoost sur l'ensemble de test.	35
3.6	Importance des variables explicatives.	36
3.7	IC à 95% par quantile regression XGBoost sur l'ensemble de test . .	37
3.8	IC à 95% du LSTM sur l'ensemble de test.	39
3.9	Prédictions XGBoost dans l'IC Schwartz sur l'ensemble de test . . .	40
3.10	Superposition des IC Schwartz et XGBoost et largeur dans le temps.	41
4.1	Trajectoires simulées du modèle deux facteurs : log-prix $X_t = c_t + l_t$	49
4.2	Reconstruction des composantes par le filtre de Kalman sur données simulées.	49
4.3	Décomposition du log-prix par le filtre de Kalman sur données réelles.	51
4.4	Décomposition de la variance entre les deux composantes filtrées. . .	52
4.5	Nuage de points $(\hat{c}_t, \hat{l}_t)$ sur l'ensemble d'entraînement.	53
4.6	Contribution des composantes filtrées lors des pics de prix (seuil $\mu + 2\sigma = 5.32$, points rouges).	54
4.7	Comparaison des distributions des résidus/innovations face à la loi normale théorique.	55

4.8	Prédictions du modèle XGBoost par composante sur l'ensemble de test.	57
4.9	Comparaison des intervalles de confiance à 95% sur l'ensemble de test.	58
4.10	Modèle LSTM sur les composantes prédit par le filtre de Kalman .	59
4.11	Intervalle de confiance généré	59
5.1	Prédiction XGBoost horaire.	65

INTRODUCTION GÉNÉRALE

Au cours des dernières années, le marché de l'électricité a connu d'importantes transformations avec la libéralisation des marchés de l'énergie et l'intégration croissante des sources d'énergie renouvelables. Ce marché se caractérise par une forte volatilité et des fluctuations rapides des prix, influencées par plusieurs facteurs tels que la demande énergétique, les conditions météorologiques, la production d'énergie renouvelable et les contraintes du réseau électrique. Cette instabilité rend la prévision des prix de l'électricité à la fois complexe et essentielle pour les différents acteurs du secteur, notamment les producteurs, les fournisseurs et les gestionnaires de réseaux.

Les méthodes classiques de prévision rencontrent généralement des difficultés à modéliser les variations brutales et les comportements irréguliers du marché. Ainsi, des approches plus avancées sont nécessaires afin d'améliorer la précision des prévisions et de mieux comprendre les dynamiques sous-jacentes.

Plusieurs méthodes de modélisation ont été proposées dans la littérature. Toutefois, leur aptitude à saisir les phénomènes non linéaires et les pics de prix demeure limitée. Selon Tzelepi [7], les prix de l'électricité présentent des caractéristiques particulières, telles que des variations extrêmes et une saisonnalité marquée, qui rendent leur modélisation complexe à l'aide de méthodes linéaires. Afin de pallier ces limites, des modèles stochastiques ont été introduits dans le domaine de la finance de l'énergie. Le modèle de Schwartz [2], largement utilisé pour la modélisation des prix des matières premières, permet de représenter le comportement aléatoire des prix ainsi que leur tendance au retour vers la moyenne. Les travaux de Senhadji El Rhazi [1], réalisés chez EDF, en proposent une implémentation rigoureuse sur le marché électrique français. Toutefois, ces modèles reposent sur des hypothèses simplificatrices qui peuvent ne pas refléter pleinement la complexité des données réelles.

Plus récemment, les méthodes d'apprentissage automatique ont démontré de

bonnes performances. Parmi elles, la forêt aléatoire est un modèle classique fondé sur un ensemble d'arbres de décision. Elle permet de prendre en compte les relations non linéaires et d'améliorer la précision des prévisions. Par ailleurs, les méthodes d'apprentissage profond ont été introduites par Hochreiter et Schmidhuber afin de mieux traiter les séries temporelles. Les réseaux LSTM permettent de capturer les dépendances temporelles à long terme [4].

Malgré ces avancées, aucun modèle unique ne permet d'obtenir des performances optimales dans toutes les situations. Cela justifie la nécessité d'une approche comparative afin d'évaluer les forces et les limites de chaque méthode.

Dans ce contexte, il convient de s'interroger sur la manière de modéliser efficacement la dynamique stochastique des prix spot de l'électricité sur le marché néerlandais, tout en permettant d'estimer les prix futurs du marché spot.

La contribution principale de ce travail consiste à proposer une approche hybride combinant la décomposition des prix obtenue à partir d'un modèle stochastique à deux facteurs avec des modèles d'apprentissage automatique. Cette approche vise à exploiter simultanément l'interprétabilité des modèles stochastiques et la capacité des modèles d'apprentissage automatique à capturer les relations non linéaires présentes dans les données. Une comparaison est ensuite menée entre les modèles stochastiques, les modèles de *Machine Learning* et les approches hybrides, en considérant à la fois la précision des prévisions ponctuelles et la qualité des intervalles de confiance.

Notre travail est structuré en cinq chapitres. Le premier expose les fondements théoriques du modèle de Schwartz. Le deuxième présente le contexte et les caractéristiques du marché d'électricité. Le troisième décrit le modèle de Schwartz à un facteur ainsi que les modèles d'apprentissage automatique classiques et leurs résultats. Le quatrième introduit le modèle de Schwartz à deux facteurs, le filtre de Kalman et les approches hybrides proposées. Enfin, le cinquième chapitre présente une comparaison globale des modèles, suivie des principales conclusions et perspectives.

CHAPITRE 1

THÉORIE : MODÈLES FACTORIELS DE SCHWARTZ

1.1 Introduction

Ce chapitre présente le modèle de Schwartz et ses différents paramètres.

1.2 Modèle factoriel de Schwartz

Le modèle de Schwartz, introduit en 1997 [2], est une référence clé dans le domaine de la modélisation des prix des matières premières. À la différence du modèle de Black-Scholes, qui est couramment utilisé pour les actions, le modèle de Schwartz prend en compte une composante essentielle : une force de rappel. Cette force de rappel tend à ramener les prix vers un niveau d'équilibre à long terme. Cette caractéristique est particulièrement pertinente sur le marché de l'électricité, où les prix ont tendance à fluctuer autour d'un niveau d'équilibre de long terme.

1.2.1 Formulation du Modèle de Schwartz

Plaçons-nous dans un cadre risque-neutre associé à une probabilité $\mathbb{Q}$. Sous cette mesure, le processus $(F(t, T))_{t \geq 0}$, représentant le prix à terme à la date t pour une livraison d'un MWh d'électricité à la date T , est une martingale locale.

Le modèle factoriel de Schwartz suppose que la dynamique de la courbe des prix à terme suit une diffusion donnée par :

$$\frac{dF(t, T)}{F(t, T)} = \sum_{k=1}^N \sigma_k(t, T) dW_t^k. \quad (1.2.1)$$

où $(W_t^1, \dots, W_t^N)$ sont des mouvements browniens indépendants, et $(\sigma_1(t, T), \dots, \sigma_N(t, T))$ représentent les volatilités à la date t pour une livraison unitaire d'électricité à la date T .

On s'intéresse particulièrement à deux cas simplifiés : le modèle à un facteur et le modèle à deux facteurs,[1] dont les dynamiques s'écrivent respectivement :

Modèle à un facteur :

$$\frac{dF(t, T)}{F(t, T)} = \sigma_c e^{-a(T-t)} dW_t^1 \quad (1.2.2)$$

Modèle à deux facteurs :

$$\frac{dF(t, T)}{F(t, T)} = \sigma_c e^{-a(T-t)} dW_t^1 + \sigma_l dW_t^2 \quad (1.2.3)$$

Dans le modèle à un facteur, le prix à terme dépend uniquement des fluctuations de court terme, caractérisées par une volatilité $\sigma_1(t, T) = \Sigma(T - t) = \sigma_c e^{-a(T-t)}$.

En revanche, le modèle à deux facteurs introduit une seconde source d'incertitude liée au long terme. Ainsi, la dynamique dépend à la fois des aléas de court terme, comme dans le modèle précédent, et des aléas de long terme, associés à une volatilité constante $\sigma_2(t, T) = \sigma_l$.

Dans les équations précédentes, chaque paramètre joue un rôle spécifique dans la modélisation des prix à terme de l'électricité :

- $F(t, T)$: représente le prix à terme de l'électricité observé à la date t pour une livraison à la date T . Il s'agit de la variable principale du modèle.
- t : date actuelle (date d'observation du prix).
- T : date de maturité ou de livraison de l'électricité.
- $\mathbb{Q}$: mesure risque-neutre sous laquelle les prix actualisés sont des martingales. Elle est utilisée pour la valorisation sans arbitrage.
- W_t^k : mouvements browniens (ou bruits aléatoires) représentant les sources d'incertitude du marché. Chaque facteur k correspond à un type de risque.
- $\sigma_k(t, T)$: volatilité associée au facteur k . Elle mesure l'intensité des fluctuations du prix. Plus σ_k est élevée, plus les prix sont volatils.
- σ_c : volatilité de court terme. Elle capture les variations rapides des prix (par exemple dues à la météo ou à la demande instantanée). Une augmentation de σ_c rend les prix plus instables à court terme.
- σ_l : volatilité de long terme. Elle représente les variations lentes et structurelles du marché (par exemple les changements économiques ou énergétiques). Une augmentation de σ_l affecte la tendance globale des prix.

- a : paramètre de décroissance (ou de réversion). Il contrôle la vitesse à laquelle l'impact des chocs de court terme diminue avec le temps.
 - Si a est grand : les effets de court terme disparaissent rapidement.
 - Si a est petit : les effets persistent plus longtemps.
- $e^{-a(T-t)}$: facteur d'atténuation temporelle. Il réduit l'impact des fluctuations de court terme lorsque la maturité T est éloignée de t . Ainsi, plus $(T - t)$ est grand, plus l'effet du court terme est faible.
- N : nombre de facteurs dans le modèle.
 - $N = 1$: modèle simple, uniquement basé sur le court terme.
 - $N = 2$: modèle plus réaliste, combinant court et long terme.

En résumé, ces paramètres permettent de capturer à la fois les fluctuations rapides (court terme) et les tendances durables (long terme), ce qui rend le modèle adapté à la forte volatilité des prix de l'électricité.

1.2.2 Analyse du prix spot

Les produits d'électricité ne sont pas délivrables le même jour, et leur prix n'est généralement pas observable sur le marché, rendant la notion de prix spot purement théorique. Il est préférable de considérer le processus logarithmique du prix spot :

$$X_t^v = \ln\left(\frac{S_t}{S_0}\right).$$

Pour le modèle à un facteur, le prix spot S_t suit une équation différentielle stochastique (EDS) spécifique :

$$dS_t = a(\theta_t - \ln S_t) S_t dt + \sigma_c S_t dW_t^1.$$

En utilisant le lemme d'Itô, le logarithme du prix spot suit une diffusion d'Ornstein-Uhlenbeck :

$$dX_t^v = a(m_t - X_t^v) dt + \sigma_c dW_t^1, \quad X_0^v = 0 \quad (1.2.4)$$

$$m_t = \ln F(0, t) + \frac{1}{a} \frac{\partial \ln F(0, t)}{\partial t} - \frac{\sigma_c^2}{4a} (1 + e^{-2at}) \quad (1.2.5)$$

Le prix peut être décomposé en une partie déterministe $S_0 D_t$ représentant la saisonnalité et une partie stochastique X_t^c intégrant la volatilité et le retour à la moyenne. Il est aisé de montrer que celui-ci est solution de la diffusion d'Ornstein-Uhlenbeck :

$$dX_t^c = a(m - X_t^c) dt + \sigma_c dW_t^1, \quad X_0^c = 0 \quad (1.2.6)$$

$$\ln S_0 D_t = \ln F(0, t) - \frac{\sigma_c^2}{4a} (1 - e^{-2at}) - m (1 - e^{-at}) \quad (1.2.7)$$

Le prix spot, dans le modèle à deux facteurs, vérifie l'équation différentielle stochastique (EDS) suivante :

$$dS_t = a \left(\theta_t - \ln S_t - \frac{1}{2} \sigma_l^2 t \right) dt + \sigma_c dW_t^1 + \sigma_l dW_t^2 \quad (1.2.8)$$

En utilisant le lemme d'Itô pour le logarithme du prix spot, on obtient une diffusion markovienne de la forme :

$$dX_t = dc_t + dl_t \quad (1.2.9)$$

avec :

$$dc_t = a(m_t - c_t) dt + \sigma_c dW_t^1 \quad (1.2.10)$$

$$dl_t = -\frac{1}{2} \sigma_l^2 dt + \sigma_l dW_t^2 \quad (1.2.11)$$

L'estimation du modèle à deux facteurs peut être effectuée à l'aide du filtre de Kalman, basé sur la maximisation de la vraisemblance des résidus. Étant donné la structure de la volatilité globale, un découplage entre le court et le long terme permet d'estimer les paramètres (a, σ_c, σ_l) . [1]

En effet, pour la composante de long terme, on suppose que les rendements logarithmiques des prix à terme suivent une marche aléatoire, soit :

$$\text{Var} \left(\ln \frac{F(t + \delta, T)}{F(t, T)} \right) = \sigma_l^2 \delta \quad (1.2.12)$$

1.2.3 La prime de risque

Lors de la phase d'estimation des paramètres du modèle à partir des données réelles du marché, on abandonne la probabilité risque-neutre $\{\mathbb{Q}\}$ au profit de la probabilité historique $\{\mathbb{P}\}$. Ce passage d'un univers à l'autre nécessite l'intégration d'un biais financier : la prime de risque (ξ_t) , ici considérée comme déterministe.

En raison de l'aversion au risque des investisseurs, l'espérance du prix à terme sous la probabilité $\{\mathbb{P}\}$ ne correspond pas exactement au prix spot attendu à l'échéance. Cette distinction est cruciale car, compte tenu du lien structurel entre les prix forward et spot, toute modification de la probabilité affecte directement la dynamique du prix spot. [1]

Pour maintenir la cohérence mathématique (où les prix à terme sont des martingales locales), on utilise le théorème de Girsanov pour effectuer le changement de probabilité $\mathbb{Q} \rightarrow \mathbb{P}$. La dynamique du prix forward $F(t, T)$ intègre alors les primes de risque liées à chaque source de bruit W^k :

$$\frac{dF(t, T)}{F(t, T)} = \sum_{k=1}^N \sigma_k(t, T) (dW^k(t) + \xi_k(t) dt) \quad (1.2.13)$$

Cas spécifiques à un et deux facteurs :

- Modèle à un facteur : la dynamique sous $\{\mathbb{P}\}$ inclut une composante de dérive (drift) liée à la volatilité court terme et à sa prime de risque associée ξ_c :

$$\frac{dF(t, T)}{F(t, T)} = \xi_c \sigma_c e^{-a(T-t)} dt + \sigma_c e^{-a(T-t)} dW_1(t).$$

- Modèle à deux facteurs : on distingue deux primes de risque (ξ_c, ξ_l) correspondant respectivement aux aléas de court terme (retour à la moyenne) et de long terme :

$$\frac{dF(t, T)}{F(t, T)} = \underbrace{\xi_c \sigma_c e^{-a(T-t)} dt + \sigma_c e^{-a(T-t)} dW_1(t)}_{\text{Composante court terme}} + \underbrace{\xi_l \sigma_l dt + \sigma_l dW_2(t)}_{\text{Composante long terme}} \quad (1.2.14)$$

1.2.4 Le modèle par produit

L'avantage majeur du modèle horaire réside dans sa précision, permettant de reconstruire le prix de n'importe quel contrat de livraison θ par simple agrégation. En l'absence d'opportunité d'arbitrage, le prix d'un produit futur $F(t, T, \theta)$ est défini comme la moyenne arithmétique des prix horaires qui le composent :

$$F(t, T, \theta) = \frac{1}{N} \sum_{i=0}^{N-1} F(t, T + ih).$$

Pour lier les prix horaires au prix moyen du produit, on utilise des coefficients appelés « facteurs de forme » (λ_i) , représentant le poids relatif de chaque heure i . Par souci de simplification et en s'appuyant sur la littérature, ces facteurs sont supposés constants et égaux à 1, signifiant une répartition uniforme de la valeur sur la période de livraison. Le passage au modèle par produit introduit une fonction d'ajustement cruciale, $\Psi(\theta)$, qui dépend de la durée de livraison :

$$\Psi(\theta) = \frac{h}{\theta} \frac{1 - e^{-a\theta}}{1 - e^{-ah}}.$$

Cette fonction modifie la dynamique de la volatilité dans les équations différentielles stochastiques (EDS) :

- Modèle à 1 facteur : $\frac{dF(t, T, \theta)}{F(t, T, \theta)} = \sigma_c e^{-a(T-t)} \Psi(\theta) dW_1(t).$
- Modèle à 2 facteurs : $\frac{dF(t, T, \theta)}{F(t, T, \theta)} = \sigma_c e^{-a(T-t)} \Psi(\theta) dW_1(t) + \sigma_l dW_2(t).$

1.2.5 Calibration des modèles

Le marché est représenté par trois paramètres clés. Cependant, un arbitrage est nécessaire : un modèle riche en paramètres exige un historique de données étendu pour être précis, mais l'instationnarité marquée du marché électrique rend l'usage de données trop anciennes inefficace. [1] Par ailleurs, il existe deux approches possibles pour l'identification des modèles :

- L'approche empirique : se base sur l'analyse statistique des données historiques de cotation.
- L'approche implicite : déduit les paramètres à partir des prix d'options observés sur le marché. C'est la méthode privilégiée pour le pricing, car elle reflète les anticipations actuelles des agents.

Sous la probabilité risque-neutre $\mathbb{Q}$, le prix d'un Call ou d'un Put européen sur un forward $F(T_0, T_f)$ est donné par une formule de type Black adaptée.

La variance totale Σ intègre à la fois la composante de court terme et celle de long terme :

$$\Sigma(t, T_0, T_f) = \frac{\sigma_c^2}{2a} \left(e^{2a(T_0 - T_f)} - e^{2a(t - T_f)} \right) + \sigma_l^2(T_0 - t) \quad (1.2.15)$$

La calibration consiste à déterminer le vecteur de paramètres $\theta = (a, \sigma_c, \sigma_l)$ qui minimise l'écart quadratique entre les prix de marché $\hat{C}_i$ et les prix issus du modèle $C_i(\theta)$:

$$\theta = \arg \min_{\theta} \sum_{i=1}^N \left(\hat{C}_i - C_i(\theta) \right)^2 \quad (1.2.16)$$

En pratique, le manque de liquidité et d'informations sur les prix des options électriques rend l'approche implicite souvent inapplicable. Les chercheurs doivent donc se tourner vers des méthodes statistiques. Celles-ci imposent des tests rigoureux :

Le premier est le test de Box-Pierce, qui vérifie l'absence d'autocorrélation dans les résidus. Sa statistique de test s'écrit :

$$BP(K) = n \sum_{k=1}^K \hat{\rho}_k^2(\hat{\varepsilon}_t) \quad (1.2.17)$$

Sous l'hypothèse nulle H_0 d'absence d'autocorrélation, la statistique $BP(K)$ suit une loi du Khi-deux à $(K - 1)$ degrés de liberté. On rejette H_0 si le quantile calculé $\alpha_K = \mathbb{P} \left(\chi_{K-1}^2 \geq \widehat{BP}(K) \right)$ est inférieur à 5%. Les résultats obtenus sur les données réelles du marché Powernext montrent que cette hypothèse est rejetée, indiquant que le modèle gaussien n'a pas réussi à capturer l'intégralité de la dynamique temporelle des prix.

Le second est le test de Jarque-Bera, qui évalue la normalité des résidus en s'appuyant sur les coefficients de Skewness S et de Kurtosis K , définis par :

$$S = \frac{\mu_3}{\mu_2^{3/2}} \quad K = \frac{\mu_4}{\mu_2^2}$$

La statistique de test s'écrit :

$$JB(n) = \frac{n-1}{6} \left(S^2 + \frac{1}{4}(K-3)^2 \right) \quad (1.2.18)$$

Sous l'hypothèse nulle H_0 de normalité, $JB(n)$ suit une loi du Khi-deux à deux degrés de liberté. On rejette H_0 si :

$$\alpha_K = \mathbb{P} \left(\chi_2^2 \geq \widehat{JB}(n) \right)$$

est inférieur à 5%. Les résultats révèlent un Kurtosis significativement supérieur à 3, traduisant la présence de queues de distribution épaisses, incompatibles avec l'hypothèse gaussienne.

Les différents tests effectués mettent bien en lumière l'inefficacité du modèle factoriel de Schwartz par rapport aux données réelles du marché électrique. En effet, les résidus de la calibration ne sont ni gaussiens ni indépendants, ce qui remet en cause les hypothèses fondamentales du modèle. Ces manquements amènent à la nécessité de recourir à des modèles de modélisation plus flexibles capables de mieux reproduire les traits empiriques des prix spot de l'électricité, notamment la présence de queues de distribution épaisses et de forts pics de prix.

CHAPITRE 2

CONTEXTE ET ANALYSE EXPLORATOIRE DES DONNÉES

2.1 Le marché électrique spot néerlandais

2.1.1 Fonctionnement du marché Day-Ahead

Le marché électrique néerlandais est intégré au marché européen interconnecté géré par le réseau européen des gestionnaires de réseau de transport d'électricité. Chaque jour à 12h00, les producteurs et consommateurs soumettent leurs offres pour les 24 heures du lendemain : le prix d'équilibre qui en résulte est le prix Day-Ahead (ou prix spot), exprimé en EUR/MWh. Ce prix est le signal économique central du marché.

2.1.2 Spécificités du marché électrique

L'électricité présente une caractéristique fondamentale qui la distingue de toutes les autres commodités : elle est **non stockable** à grande échelle. Cette contrainte impose un équilibre instantané entre production et consommation, générant des dynamiques de prix radicalement différentes de celles observées sur les marchés financiers classiques. Trois caractéristiques fondamentales sont identifiées que tout modèle doit reproduire [1] :

1. **Saisonnalité** : les prix varient de façon périodique selon l'heure de la journée, le jour de la semaine et la saison de l'année, reflétant la variabilité des cycles de consommation industrielle et domestique.

2. **Retour à la moyenne** : les prix tendent à revenir autour d'un niveau d'équilibre moyen, conséquence directe de l'équilibre structurel entre coûts de production et demande.
3. **Pics de prix** : des variations brutales et discontinues liées aux déséquilibres transitoires entre offre et demande, aux coûts de production par paliers et à la non-stockabilité.

À ces caractéristiques historiques s'ajoute, dans le contexte du marché néerlandais moderne, un phénomène inexistant en 2004 : les prix négatifs, résultant de la surproduction des énergies renouvelables intermittentes (solaire, éolien) lors d'épisodes de faible demande.

2.2 Données utilisées

2.2.1 Source et description

Les données utilisées dans ce travail proviennent de la plateforme *ENTSO-E Transparency Platform*, qui publie en accès libre les prix Day-Ahead de l'ensemble des marchés électriques européens. Les données couvrent le marché néerlandais sur la période janvier 2024 – juin 2026 :

TABLE 2.1 – Description des fichiers de données

Fichier	Résolution	Observations	Période
prices_2024	Horaire (1h)	8 783	2024
prices_2025	15 minutes	35 039	2025
prices_2026	15 minutes	16 699	janv.–juin 2026

2.2.2 Traitement des données

Les trois fichiers présentent des résolutions temporelles différentes. Pour obtenir une série homogène, les données sont agrégées en moyenne journalière. Le résultat est une série de **905 jours** journaliers (2024-01-01 → 2026-06-23).

Traitement des prix négatifs : Trois jours présentent un prix moyen journalier négatif (0.3% du dataset). Le modèle de Schwartz travaillant sur le log-prix $X_t = \ln(S_t)$, une transformation directe est impossible pour des valeurs négatives ou nulles. On applique un décalage minimal :

$$X_t = \ln(S_t + \text{shift}), \quad \text{shift} = |S_{\min}| + 1 \quad (2.2.1)$$

Ce décalage rend tous les prix strictement positifs avant transformation, tout en préservant la structure de dépendance temporelle. Les prédictions sont ramenées à l'espace des prix réels par $\hat{S}_t = e^{\hat{X}_t} - \text{shift}$.

2.3 Analyse exploratoire des données

L'analyse exploratoire est conduite sur l'année 2025 uniquement, seule année complète disponible dans le dataset, permettant une analyse saisonnière sans effets de bord.

2.3.1 Vue d'ensemble de l'année 2025




FIGURE 2.1 – Vue d'ensemble du marché électrique néerlandais en 2025.

Les trois graphiques de la Figure 2.1 illustrent les caractéristiques fondamentales du marché spot :

Prix horaire : Le prix spot présente une forte variabilité autour de la moyenne annuelle de **86.8 EUR/MWh**. On observe clairement les trois caractéristiques du marché électrique :

- Des pics de prix positifs importants (jusqu'à ≈ 450 EUR/MWh en janvier 2025, période de forte demande hivernale), signature des déséquilibres offre-demande instantanés

- Des prix négatifs (zones rouges, principalement mai 2025) liés aux excédents de production solaire et éolienne, phénomène spécifique aux marchés modernes avec forte pénétration des renouvelables.
- Une volatilité asymétrique : les hausses extrêmes sont plus importantes que les baisses extrêmes.

Prix journalier : La moyenne journalière révèle une **saisonnalité annuelle claire** : prix élevés en hiver (jan–fév 2025, ≈ 120 EUR/MWh) et prix bas au printemps/été (avr–mai 2025, ≈ 40 – 70 EUR/MWh), liée aux cycles de consommation de chauffage et à la production solaire estivale.

La zone ± 1 écart-type montre une dispersion importante ($\approx \pm 40$ EUR/MWh) reflétant l’incertitude structurelle du marché.

Log-prix journalier : Le logarithme du prix (après décalage) oscille autour de sa moyenne (4.500) avec un retour à la moyenne visible, les déviations positives et négatives sont systématiquement résorbées. C’est la justification empirique du processus d’Ornstein-Uhlenbeck retenu pour la modélisation. Les creux profonds (≈ 2.5 – 3.0) correspondent aux épisodes de prix très bas (mai 2025) que le modèle gaussien peine à capturer.

2.3.2 Saisonnalité mensuelle et hebdomadaire




FIGURE 2.2 – Saisonnalité mensuelle et hebdomadaire

Distribution par mois : La saisonnalité annuelle est clairement visible :

- Hiver (Jan–Fév) : prix médians élevés (≈ 115 – 130 EUR/MWh), forte demande de chauffage, faible production solaire ;
- Printemps–Été (Mai–Juil) : prix médians bas (≈ 65 – 75 EUR/MWh), forte production solaire, faible demande de chauffage. Mai présente les prix les plus bas et la plus forte dispersion, cohérent avec les épisodes de prix négatifs

- Automne–Hiver (Oct–Déc) : remontée progressive des prix avec l’augmentation de la demande.

Les nombreux outliers (cercles) visibles sur tous les mois confirment la présence de pics de prix extrêmes non capturables par un modèle gaussien simple.

Distribution par jour de la semaine : L’effet week-end est clairement identifié. Les jours de semaine présentent des prix médians nettement plus élevés (≈ 93 EUR/MWh, médiane 88 EUR/MWh) contre le week-end (≈ 71 EUR/MWh, médiane 71 EUR/MWh), soit un **différentiel de 21.5 EUR/MWh** lié à la baisse de la consommation industrielle.

2.3.3 Saisonnalité intra-journalière




FIGURE 2.3 – Saisonnalité intra-journalière.

Le profil intra-journalier révèle une structure en **double crête** caractéristique des marchés électriques européens :

- **Creux nocturne** (3h–6h) : prix minimal (≈ 80 EUR/MWh) lié à la faible consommation nocturne ;
- **Pic matinal** (7h–8h) : hausse rapide lors de la reprise d’activité industrielle et domestique (≈ 120 EUR/MWh en semaine) ;
- **Creux de mi-journée** (12h–14h) : baisse marquée liée à la forte production solaire photovoltaïque (≈ 40 EUR/MWh), creux beaucoup plus prononcé le week-end (≈ 20 EUR/MWh) car la production solaire s’ajoute à une demande industrielle faible ;
- **Pic du soir** (19h–20h) : pic le plus élevé de la journée (≈ 130 – 140 EUR/MWh) correspondant à la reprise de consommation après le travail et la baisse de la production solaire.

Le différentiel semaine/week-end est maximal entre 8h et 16h, précisément les heures de forte activité industrielle en semaine et de forte production solaire. La heatmap confirme ces observations : la zone rouge (prix élevés) se concentre sur les heures du soir (18h–21h) en automne-hiver, tandis que la zone verte foncée (prix bas) correspond aux heures de mi-journée (11h–15h) au printemps-été.

2.3.4 Distribution et dépendances temporelles




FIGURE 2.4 – Distribution et dépendances temporelles NL 2025.

Distribution des prix bruts : La distribution est fortement asymétrique à droite (queue vers les prix élevés) avec un pic autour de 80–90 EUR/MWh. La loi normale théorique sous-estime significativement la fréquence des valeurs proches de la médiane et l’amplitude des queues. Le QQ-plot confirme visuellement le rejet de la normalité : les points s’écartent de la droite théorique dans les deux queues, particulièrement dans la queue supérieure.

Distribution du log-prix : La transformation logarithmique améliore l’adéquation à la normale mais un pic central très prononcé subsiste, kurtosis supérieur à 3, queues encore plus épaisses que la normale. Cette observation justifie l’approche

par processus d’Ornstein-Uhlenbeck sur le log-prix tout en soulignant ses limites gaussiennes.

TABLE 2.2 – Tests de normalité : prix bruts et log-prix journaliers 2025

Série	Skewness	Kurtosis	JB p-value
Prix bruts	0.449	4.826	0.0 → Non normal
Log-prix	−1.967	11.190	0.0 → Non normal

Dépendances temporelles : L’autocorrélation du prix journalier est **fortement significative** et présente une **structure périodique de période 7** (pics aux lags 7, 14, 21...), signature directe de la saisonnalité hebdomadaire. Cette autocorrélation persistante viole l’hypothèse de bruit blanc et justifie l’utilisation de lags dans le feature engineering des modèles ML.

La **volatilité glissante** (fenêtre 30 jours) n’est pas constante dans le temps (hétéroscédasticité) : forte en début d’année (jan–mars 2025, $\approx 35\text{--}40$ EUR/MWh), faible en été (juil–sept 2025, ≈ 15 EUR/MWh), puis reprise en automne (≈ 35 EUR/MWh). Cette hétéroscédasticité constitue une limite supplémentaire du modèle de Schwartz à volatilité constante (σ fixe) et une source d’information potentielle pour les modèles ML.

2.3.5 Analyse des prix négatifs




FIGURE 2.5 – Analyse des prix négatifs

Les prix négatifs constituent un phénomène spécifique aux marchés électriques modernes avec forte pénétration des énergies renouvelables. Sur l’année 2025 :

- 584 heures à prix négatif sur 8 760 heures annuelles, soit 6.7% du temps

- Prix négatif moyen : -12.05 EUR/MWh
- Prix négatif minimum : -350.00 EUR/MWh, événement extrême correspondant à une surproduction massive non absorbable par le réseau.

Les trois mois avec le plus de prix négatifs sont mai (19.5%), juin (17.6%) et avril (11.7%), ce qui correspond exactement au pic de production solaire photovoltaïque (ensoleillement maximal, journées longues) combiné à une demande modérée (températures douces, pas de chauffage). Les prix négatifs se concentrent sur la plage horaire 10h–16h, absents la nuit et rares en soirée.

Ces prix négatifs posent un défi spécifique pour la modélisation :

1. Le modèle de Schwartz : ne peut pas appliquer le logarithme directement, un décalage minimal est appliqué .
2. Les modèles ML (XGBoost, LSTM) traitent les prix négatifs comme n’importe quelle valeur numérique, sans contrainte de positivité, avantage structurel par rapport aux modèles stochastiques gaussiens.

2.3.6 Synthèse

TABLE 2.3 – Synthèse statistique NL 2025 (données horaires)

Statistique	Valeur
Prix moyen	86.8 EUR/MWh
Prix médian	≈ 84 EUR/MWh
Prix minimum	-350.0 EUR/MWh
Prix maximum	$\approx +450$ EUR/MWh
% heures à prix négatif	6.7%
Mois le plus cher	Février (≈ 126 EUR/MWh)
Mois le moins cher	Mai (≈ 64 EUR/MWh)
Différentiel sem./week-end	21.5 EUR/MWh
Saisonnalité hebdomadaire	Significative (période 7)
Saisonnalité horaire	Double crête (8h et 20h)
Normalité (JB test)	Rejetée (prix bruts et log-prix)
Hétéroscédasticité	Présente

L’analyse exploratoire confirme que les caractéristiques du marché électrique néerlandais [1], enrichies par des phénomènes modernes liés à la transition énergétique. Ces observations fondent les choix de modélisation développés dans les chapitres suivants.

CHAPITRE 3

MODÈLE DE SCHWARTZ À UN FACTEUR

Ce chapitre présente la mise en œuvre du modèle de Schwartz à un facteur sur les données réelles du marché électrique néerlandais.

3.1 Rappel théorique

3.1.1 Modèle continu

Le modèle de Schwartz à un facteur modélise le log-prix $X_t = \ln(S_t + \text{shift})$ par un processus d'Ornstein-Uhlenbeck :

$$dX_t = a(m - X_t) dt + \sigma dW_t \quad (3.1.1)$$

où $a > 0$ est la vitesse de retour à la moyenne, m le niveau moyen long terme et σ la volatilité. La solution exacte de cette EDS est :

$$X_t | X_0 \sim \mathcal{N}\left(m + (X_0 - m)e^{-at}, \frac{\sigma^2}{2a}(1 - e^{-2at})\right) \quad (3.1.2)$$

Ce processus est gaussien par nature : ses incréments suivent une loi normale. [8]
La demi-vie de retour à la moyenne est $\tau_{1/2} = \ln(2)/a$.

3.1.2 Justification du cas désaisonnalisé (m constante)

on distingue deux variantes selon le traitement de la tendance [1] :

- **Cas constant** (désaisonnalisé) : m est supposée constante dans le temps. C'est le cas étudié dans ce travail.

- **Cas variable** (saisonnalisé) : m_t dépend du temps via la courbe forward initiale $F(0, t)$, intégrant la saisonnalité horaire, hebdomadaire et annuelle.

Le choix du cas constant est motivé par trois raisons :

1. **Disponibilité des données** : le modèle variable nécessite une courbe forward complète $F(0, t)$, non disponible directement sur la plateforme ENTSO-E pour le marché néerlandais.
2. **Rigueur de la validation** : la simulation de validation (Section 3.3) est plus rigoureuse dans ce cadre, où les paramètres vrais (a, m, σ) sont entièrement contrôlables.
3. **Équité de la comparaison** : les modèles ML (XGBoost, LSTM) ne disposent que des prix passés en entrée, utiliser le modèle constant garantit une comparaison sur un pied d'égalité.

Le modèle variable constitue une extension naturelle mentionnée en perspective [1].

3.2 Discrétisation et estimation

3.2.1 Modèle discret AR(1)

En intégrant exactement l'équation (3.1.1) sur un intervalle de pas h , on obtient un processus **AR(1)** :

$$X_i = \phi_0 + \phi_1 X_{i-1} + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_\varepsilon^2) \quad (3.2.1)$$

avec les relations bijectives :

$$\phi_1 = e^{-ah}, \quad \phi_0 = m(1 - e^{-ah}), \quad \sigma_\varepsilon = \sigma \sqrt{\frac{1 - e^{-2ah}}{2a}} \quad (3.2.2)$$

Les paramètres physiques (a, m, σ) se récupèrent par inversion :

$$a = -\frac{\ln \phi_1}{h}, \quad m = \frac{\phi_0}{1 - \phi_1}, \quad \sigma = \sigma_\varepsilon \sqrt{\frac{2a}{1 - e^{-2ah}}} \quad (3.2.3)$$

Pourquoi cette discrétisation et pas une autre ? Il existe deux approches pour discrétiser une EDS : le schéma d'Euler (approximation au premier ordre) et la solution exacte. On utilise ici la solution exacte car elle est valide pour tout pas h sans biais de discrétisation, et elle préserve exactement les propriétés statistiques du processus continu (loi conditionnelle gaussienne, variance asymptotique $\sigma^2/(2a)$).

3.2.2 Estimation par MCO

Les paramètres (ϕ_0, ϕ_1) sont estimés par moindres carrés ordinaires (MCO), en posant le problème de régression [1] :

$$\mathbf{B} = A\boldsymbol{\phi} + \boldsymbol{\varepsilon}, \quad A = \begin{bmatrix} 1 & X_0 \\ \vdots & \vdots \\ 1 & X_{n-1} \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad (3.2.4)$$

L'estimateur MCO est :

$$\hat{\boldsymbol{\phi}} = (A^T A)^{-1} A^T \mathbf{B} \quad (3.2.5)$$

3.2.3 Estimation par maximum de vraisemblance (EMV)

La log-vraisemblance du modèle AR(1) gaussien est :

$$\mathcal{L}(\phi_0, \phi_1, \phi_2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \phi_2 - \frac{1}{2} e^{-\phi_2} \sum_{i=1}^n (X_i - \phi_1 X_{i-1} - \phi_0)^2 \quad (3.2.6)$$

où $\phi_2 = \ln(\sigma_\varepsilon^2)$ assure la positivité de la variance.

Équivalence MCO/EMV : Maximiser $\mathcal{L}$ par rapport à (ϕ_0, ϕ_1) est strictement équivalent à minimiser la somme des carrés des résidus, autrement dit, MCO et EMV produisent les mêmes estimateurs pour ce modèle AR(1) gaussien. [1] Cette équivalence sera vérifiée numériquement.

Condition initiale pour l'EMV : L'optimisation numérique (algorithme de Nelder-Mead) est initialisée selon :

$$\hat{m}_0 = \bar{X}, \quad \hat{\phi}_{1,0} = \frac{1}{2} \left(\frac{X_2 - \bar{X}}{X_1 - \bar{X}} - \frac{X_1 - \bar{X}}{\bar{X}} \right), \quad \hat{\phi}_{0,0} = \hat{m}_0(1 - \hat{\phi}_{1,0}) \quad (3.2.7)$$

3.3 Simulation de validation

3.3.1 Protocole

Avant toute application sur données réelles, on valide l'estimateur par simulation : on fixe des paramètres vrais, on simule $k = 100$ trajectoires de $n = 730$ observations

($h = 1/365$, soit 2 ans), on calibre MCO et EMV, et on compare les estimées aux vraies valeurs.

Paramètres vrais retenus :

$$a_{\text{true}} = 150 \text{ ans}^{-1}, \quad m_{\text{true}} = 3.5, \quad \sigma_{\text{true}} = 8.0 \quad (3.3.1)$$




FIGURE 3.1 – Trajectoire simulée du log-prix X_t (processus d’Ornstein-Uhlenbeck

La trajectoire simulée illustre les deux caractéristiques fondamentales du modèle d’Ornstein-Uhlenbeck : les fluctuations autour de la moyenne long terme m (ligne rouge pointillée), et le retour à cette moyenne après chaque déviation. Plus la vitesse a est élevée, plus ce retour est rapide. le paramètre σ contrôle l’amplitude des fluctuations, tandis que a contrôle leur persistance.

3.3.2 Comparaison MCO vs EMV

TABLE 3.1 – Comparaison MCO/EMV sur données simulées

Paramètre	MCO	EMV	Écart relatif (%)
a	169.290911	169.290624	0.000169
m	3.485421	3.485396	0.000702
σ	8.040015	8.040027	0.000143

Les deux méthodes d’estimation donnent des résultats quasi-identiques, avec des écarts relatifs proches de zéro. Pour ce modèle AR(1) gaussien, maximiser la log-vraisemblance est strictement équivalent à minimiser la somme des carrés des résidus. Dans la suite, on retient l’estimateur MCO pour sa simplicité et sa rapidité de calcul.

3.3.3 Résultats de la simulation de validation

TABLE 3.2 – Robustesse de l’estimateur MCO $k = 100$ simulations

Paramètre	Vraie valeur	Moyenne MCO	Écart-type
a (ans ⁻¹)	150.0	150.325020	14.100997
m	3.5	3.501800	0.038273
σ	8.0	7.993861	0.260201

Sur 100 simulations indépendantes, la moyenne des paramètres estimés est très proche des vraies valeurs fixées, et les écarts-types sont faibles ce qui confirme que l’estimateur est sans biais et convergent.

3.3.4 Tests des résidus simulés

TABLE 3.3 – Tests statistiques sur les résidus simulés

	Skewness	Kurtosis	JB p-value	BP p-value
Résidus simulés (MCO)	0.1297	3.182	0.218	0.903

Par construction, les résidus issus de données simulées par un processus gaussien doivent se comporter comme un bruit blanc gaussien. Les p-values élevées des tests de Box-Pierce (absence d’autocorrélation) et de Jarque-Bera (normalité) confirment que l’estimateur MCO restitue des résidus cohérents avec les hypothèses du modèle. Ce résultat sert de référence pour la comparaison avec les résidus réels, où on s’attend au contraire à un rejet de ces hypothèses.

3.4 Calibration sur données réelles

3.4.1 Données

Les données utilisées sont les prix spot Day-Ahead, agrégés en moyenne journalière ($h = 1$ jour) sur la période 2024–2026 ($n = 905$ jours). Un décalage $\text{shift} = |p_{\min}| + 1$ est appliqué avant transformation logarithmique pour traiter les prix négatifs.

Le découpage entraînement/test retenu est 80%/20% chronologique, soit 724 jours en entraînement et 181 jours en test.




FIGURE 3.2 – Visualisation les données 2024-2026.

On retrouve les trois caractéristiques fondamentales du marché électrique :

- Graphique gauche : présence de pics de prix importants, accentués par la non-stockabilité de l’électricité et les variations discontinues des coûts de production.
- Graphique centre : saisonnalité visible sur le court terme, variations journalières et hebdomadaires.
- Graphique droite : le logarithme du prix montre un retour à la moyenne caractéristique, signature du processus d’Ornstein-Uhlenbeck.

3.4.2 Paramètres estimés

TABLE 3.4 – Paramètres calibrés du modèle un facteur sur données réelles

Paramètre	MCO	EMV	Écart relatif (%)	Unité
a	0.7643	0.7642	0.002	jours ⁻¹
m	4.4361	4.4361	< 0.001	—
σ	0.5445	0.5445	< 0.001	—

Interprétation des paramètres.

- $a = 0.764$ **jours⁻¹** : demi-vie $\tau_{1/2} = \ln(2)/0.764 \approx$ **0.91 jour**. Les chocs de prix sont résorbés en moins d’une journée cohérent avec la nature très réactive du marché électrique spot.
- $m = 4.436$: niveau moyen du log-prix décalé, soit $e^{4.436} - \text{shift} \approx 84$ EUR/MWh, cohérent avec le prix moyen observé sur 2024–2026.
- $\sigma = 0.545$: volatilité journalière du log-prix.
- Écarts MCO/EMV quasi-nuls (< 0.003%) : confirme numériquement l’équivalence théorique pour ce modèle AR(1) gaussien.

3.5 Tests des résidus réels




FIGURE 3.3 – Résidus MCO sur l’ensemble d’entraînement.

Les deux graphiques révèlent des déviations significatives par rapport à l’hypothèse de bruit blanc gaussien :

Histogramme : la distribution empirique des résidus (barres bleues) présente un pic central beaucoup plus prononcé que la loi normale théorique (courbe rouge), ainsi qu’une asymétrie visible vers la gauche. Cette forme leptokurtique (queues épaisses, Kurtosis > 3) est la signature directe des pics de prix extrêmes que le modèle gaussien ne peut pas reproduire.

Résidus dans le temps : on observe des résidus extrêmes isolés (valeurs autour de -4 vers le jour 130-150, et autour de -2.5 vers le jour 175), qui correspondent à des épisodes de prix spot anormalement bas ou négatifs, phénomène lié aux surplus de production d’énergie renouvelable. En dehors de ces épisodes, les résidus semblent globalement stationnaires, ce qui valide partiellement la stationnarité du processus.

Ainsi, l’hypothèse de bruit blanc gaussien est rejetée, ce qui confirme l’inadéquation du modèle gaussien un facteur pour capturer la dynamique réelle des prix spot.

TABLE 3.5 – Tests statistiques comparés : résidus simulés vs résidus réels

	Skewness	Kurtosis	JB p-value	BP p-value
Résidus simulés (référence)	0.130	3.182	0.218	0.903
Résidus réels	-3.112	28.061	0.0	2.6×10^{-125}

- Le Kurtosis est sensiblement supérieur à 3 (référence loi normale), révélant des queues de distribution épaisses, signature des pics de prix extrêmes que le modèle gaussien ne peut pas reproduire.
- Le test de Jarque-Bera rejette l’hypothèse de normalité (p-value faible).

- Le test de Box-Pierce peut révéler une autocorrélation résiduelle, indiquant que la structure temporelle du marché n'est pas entièrement capturée par le modèle un facteur à tendance constante.

Conclusion : Le processus d'Ornstein-Uhlenbeck est gaussien par construction, ses résidus sont supposés suivre $\mathcal{N}(0, \sigma_\varepsilon^2)$. Le rejet de cette hypothèse sur données réelles ne remet pas en cause la validité mathématique du modèle, mais confirme son inadéquation pour décrire la dynamique des prix spot électriques. La non-gaussianité est intrinsèque aux données (pics, prix négatifs, sauts) et ne peut pas être capturée par un seul bruit brownien gaussien. Ce constat motive directement le recours au modèle Machine Learning.

3.6 Prédiction et intervalles de confiance

3.6.1 Formule analytique

La solution (3.1.2) fournit directement l'espérance et la variance conditionnelles à horizon τ :

$$\mathbb{E}[X_{t+\tau} \mid X_t] = m + (X_t - m)e^{-a\tau} \quad (3.6.1)$$

$$\text{Var}[X_{t+\tau} \mid X_t] = \frac{\sigma^2}{2a}(1 - e^{-2a\tau}) \quad (3.6.2)$$

L'intervalle de confiance à 95% est :

$$\text{IC}_{95\%} = \mathbb{E}[X_{t+\tau}] \pm 1.96\sqrt{\text{Var}[X_{t+\tau}]} \quad (3.6.3)$$

Remarque méthodologique : Cette prédiction est *multi-step* depuis le dernier point du train set X_0 : on projette l'espérance sur tout le test set depuis un seul point de départ. Contrairement aux modèles ML (prédiction à un pas, utilisant les vraies valeurs passées), la prédiction de Schwartz converge rapidement vers m sans recalage dynamique. Cette asymétrie favorise les modèles ML sur la métrique MAE/RMSE et elle est mentionnée comme limite méthodologique.

3.6.2 Validation Monte Carlo

On simule $k = 2000$ trajectoires depuis X_0 avec les paramètres calibrés, et on compare les percentiles empiriques 2.5% et 97.5% à la formule analytique. La convergence est vérifiée à plusieurs horizons.

3.6.3 Résultats sur l'ensemble d'entraînement




FIGURE 3.4 – Prédiction du modèle de Schwartz et IC à 95% sur l'ensemble de test

Ce graphique illustre parfaitement à la fois les forces et les limites du modèle de Schwartz un facteur. Ce qu'on observe :

- La prédiction ponctuelle (ligne bleue horizontale) converge immédiatement vers la moyenne long terme m et reste quasi-constante sur tout l'horizon de prédiction. C'est la conséquence directe du retour à la moyenne : dès que l'horizon dépasse quelques jours, l'espérance conditionnelle $\mathbb{E}[X_{t+\tau}] = m + (X_0 - m)e^{-a\tau}$ tend vers m , rendant la prédiction plate et non informative sur le moyen/long terme.
- L'IC à 95% (zone bleue) est large et quasi-constant, il s'élargit légèrement au début puis se stabilise rapidement autour de la variance asymptotique $\sigma^2/2a$. Cela explique la couverture empirique élevée de 98.3% : l'IC est suffisamment large pour capturer presque toutes les observations réelles.
- Le log-prix réel (ligne noire) présente des dynamiques que le modèle ne peut pas anticiper : saisonnalité hebdomadaire visible, et surtout trois chutes brutales (vers les jours 820, 850 et 855) correspondant à des épisodes de prix très bas ou négatifs (log-prix descendant jusqu'à 2.5, soit des prix spot autour de 12 €/MWh après décalage). Ces épisodes sortent momentanément de l'IC avant d'y revenir, le modèle gaussien sous-estime la probabilité de tels événements extrêmes.

Conclusion : le modèle de Schwartz fournit un IC globalement fiable mais au prix d'une prédiction ponctuelle peu précise et d'un intervalle trop large pour être exploitable en trading. C'est précisément ce qu'on cherche à améliorer.

TABLE 3.6 – Performances du modèle de Schwartz 1F sur l'ensemble d'entraînement

Métrique	Valeur
MAE	0.2948
RMSE	0.3840
Couverture IC 95%	98.3%
Largeur moyenne IC	1.726

3.7 Modèle XGBoost

3.7.1 Principe et ingénierie des variables explicatives

XGBoost est un modèle d'arbres de décision boostés qui prédit X_t directement depuis un vecteur de features construites à partir du passé.[5] Contrairement à Schwartz, il ne suppose aucune forme fonctionnelle a priori sur la distribution du bruit.

Les features retenues sont :

- **Lags** $\{1, 2, 3, 4, 5, 6, 7\}$ jours : valeurs passées du log-prix ;
- **Variables calendaires** : `is_weekend`, `dayofweek`, `month` ;
- **Statistiques glissantes** : moyenne et écart-type sur 7 jours.

3.7.2 Hyperparamètres

TABLE 3.7 – Hyperparamètres du modèle XGBoost

Hyperparamètre	Valeur	Justification
<code>n_estimators</code>	300	Convergence stable sans surapprentissage
<code>max_depth</code>	4	Arbres peu profonds, évite le surapprentissage
<code>learning_rate</code>	0.05	Taux faible, convergence progressive
<code>subsample</code>	0.8	Régularisation par sous-échantillonnage
<code>colsample_bytree</code>	0.8	Régularisation sur les features

3.7.3 Intervalle de confiance par quantile regression

L'IC à 95% est obtenu en entraînant deux modèles XGBoost supplémentaires . Cette approche ne suppose aucune distribution pour les résidus, avantage majeur par rapport à l'IC analytique gaussien de Schwartz.

Résultats




FIGURE 3.5 – Prédiction XGBoost sur l'ensemble de test.

Contrairement au modèle de Schwartz (ligne plate convergeant vers m), XGBoost produit une prédiction dynamique qui suit fidèlement les fluctuations réelles du log-prix.

Plusieurs observations importantes :

- Sur les régimes normaux (jours 0-80 et 130-180), la courbe verte suit de très près la courbe noire, capturant la saisonnalité hebdomadaire et les tendances de court terme grâce aux features de lags et variables calendaires.
- Sur les épisodes de baisse brutale (jours 95-130), XGBoost détecte bien la direction de la chute mais en sous-estime l'amplitude notamment le pic extrême vers le jour 125 (log-prix 2.3, correspondant à des prix spot très bas). Ce comportement est attendu : les arbres de décision extrapolent mal les valeurs hors de la plage d'entraînement.
- La MAE de 0.241 et le RMSE de 0.357 confirment quantitativement cette bonne adéquation sur la majorité du test set, avec une amélioration de 18% et 7% respectivement par rapport au modèle de Schwartz.




FIGURE 3.6 – Importance des variables explicatives.

Ce graphique révèle quelles informations le modèle exploite pour prédire le log-prix, et confirme la pertinence du feature engineering réalisé :

- ‘is_weekend’ (26%) et ‘dayofweek’ (19%) sont les deux variables les plus importantes, représentant ensemble 45% du pouvoir prédictif total. Ce résultat est cohérent avec la structure du marché électrique : les prix sont structurellement plus bas le week-end (faible demande industrielle), une saisonnalité que le modèle de Schwartz à tendance constante ne peut pas capturer explicitement.
- lag_1’ (15%) arrive en troisième position, le prix d’hier est un prédicteur fort du prix d’aujourd’hui, ce qui reflète l’autocorrélation de court terme de la série (retour à la moyenne). C’est l’équivalent implicite du paramètre ϕ_1 dans le modèle AR(1) de Schwartz.
- ‘rolling_mean_7’ (7%) capture la tendance récente sur 7 jours, jouant un rôle similaire à la moyenne long terme m dans Schwartz mais de façon adaptative.
- Les lags 2 à 7 et la volatilité glissante (‘rolling_std_7’) contribuent chacun modestement (3-5%), suggérant que l’information utile est principalement concentrée dans le court terme immédiat et la structure calendaire.

La domination des variables calendaires sur les lags montre que XGBoost exploite principalement la saisonnalité hebdomadaire, une dimension que le modèle de Schwartz un facteur à tendance constante ignore complètement, ce qui explique en partie son avantage en MAE/RMSE.




FIGURE 3.7 – IC à 95% par quantile regression XGBoost sur l'ensemble de test

L'IC de XGBoost (zone verte) présente des propriétés qualitativement différentes de celui de Schwartz :

- L'IC est dynamique : sa largeur varie selon le régime de marché. Il se resserre dans les périodes calmes (jours 130-180, largeur 0.5) et s'élargit dans les périodes volatiles (jours 0-30 et 90-130, largeur 1.0-1.5). Cette adaptation est un avantage majeur par rapport à l'IC de Schwartz qui reste quasi-constant à 1.73.
- Sur les épisodes extrêmes (jours 95-130), l'IC s'élargit correctement pour anticiper l'incertitude accrue, mais ne descend pas suffisamment bas pour capturer le pic extrême du jour 125 (log-prix 2.3), ce qui contribue à la couverture de 82.8% inférieure à la cible de 95%.
- La prédiction médiane (ligne verte foncée) est nettement plus proche du prix réel que la prédiction de Schwartz, au prix d'une couverture moins fiable sur les événements rares.

XGBoost offre un IC plus précis et adaptatif en régime normal, mais sous-estime l'incertitude lors des épisodes extrêmes, exactement là où une bonne quantification de l'incertitude serait la plus précieuse pour un opérateur de marché.

3.8 Modèle LSTM

3.8.1 Principe et justification de l'architecture

Le LSTM (Long Short-Term Memory) apprend directement la dépendance temporelle dans la séquence brute des prix via ses trois portes (oubli, entrée, sortie), sans construction manuelle de features.[4]

Pourquoi pas BiLSTM ? Le BiLSTM lit la séquence dans les deux sens. En prédiction de séries temporelles, la direction inverse utilise des valeurs futures lors de l’entraînement.

3.8.2 Validation empirique de la longueur de séquence

La longueur de séquence T est le premier hyperparamètre à valider car il conditionne la quantité d’historique exploitée par le LSTM.

TABLE 3.8 – Validation empirique de T

T (jours)	MAE	RMSE
7	0.2694	0.3680
14	0.2840	0.3804
30	0.2927	0.3924
60	0.2791	0.4009

$T = 7$ minimise la MAE et le RMSE. Ce résultat est cohérent avec deux observations :

- la saisonnalité hebdomadaire est le facteur dominant (`is_weekend` 26% dans XGBoost)
- la demi-vie calibrée (~ 1 jour) indique une mémoire très courte des chocs.

3.8.3 Architecture retenue

TABLE 3.9 – Architecture LSTM et justification des hyperparamètres

Composant	Valeur	Justification
Séquence T	7 jours	Validé empiriquement
LSTM couche 1	64 unités	Capture patterns hebdomadaires
LSTM couche 2	32 unités	Entonnoir progressif, synthèse
Dropout	0.2	Régularisation + Monte Carlo Dropout
Dense	16 (ReLU)	Combinaison non linéaire finale
Optimizer	Adam	Adaptatif, robuste séries temporelles
Loss	MAE	Robuste aux pics extrêmes
Early Stopping	patience=15	Arrêt sur validation, évite surapprentissage
Batch size	32	Compromis vitesse/stabilité

Le double rôle du *Dropout* mérite d’être souligné :

- régularisation pendant l'entraînement
- approximation bayésienne à l'inférence (Monte Carlo *Dropout*) pour la construction de l'IC.

3.8.4 Intervalles de confiance par Monte Carlo *Dropout*

En activant le *Dropout* à l'inférence et en moyennant 200 prédictions stochastiques, on obtient une distribution empirique de la prédiction dont les percentiles 2.5% et 97.5% définissent l'IC à 95% approximation bayésienne ne supposant aucune distribution paramétrique.

3.8.5 Résultats




FIGURE 3.8 – IC à 95% du LSTM sur l'ensemble de test.

Le LSTM entraîné sur des séquences de 7 jours présente un profil de performance distinct des approches précédentes :

Précision ponctuelle : avec une MAE de 0.2694 et un RMSE de 0.3680, le LSTM se positionne entre Schwartz (MAE=0.295) et XGBoost (MAE=0.241). Cette performance intermédiaire est cohérente avec la taille limitée du jeu de données (700 observations), le deep learning nécessite généralement davantage de données que le gradient boosting pour exprimer pleinement son potentiel.

Intervalle de confiance : le Monte Carlo Dropout produit un IC à 95% avec une couverture empirique de 97.0%, la plus proche de la cible théorique après Schwartz (98.3%). La largeur de 1.400 est intermédiaire entre Schwartz (1.726) et XGBoost hybride (0.998), reflétant une estimation de l'incertitude plus conservatrice que la quantile regression mais plus informative que l'IC analytique de Schwartz.

Ce résultat met en évidence une propriété importante du Monte Carlo Dropout : en activant le Dropout à l'inférence et en moyennant 200 prédictions stochastiques, on obtient une approximation bayésienne de l'incertitude qui tend à mieux couvrir les événements rares que les approches fréquentistes (quantile regression).

3.9 Comparaison des modèles

3.9.1 Précision ponctuelle

TABLE 3.10 – Performances comparées : Schwartz 1F, XGBoost, LSTM

Modèle	MAE	RMSE	Couverture IC 95%	Largeur IC
Schwartz 1F	0.2948	0.3840	98.3%	1.726
XGBoost	0.2410	0.3569	82.8%	0.769
LSTM	0.2694	0.3680	97.1%	1.400




FIGURE 3.9 – Prédictions XGBoost dans l'IC Schwartz sur l'ensemble de test

Ce graphique répond à la question : *les prédictions de XGBoost sont-elles cohérentes avec le cadre probabiliste de Schwartz ?*

- **Points verts (177 points dans l'IC)** : la grande majorité des prédictions XGBoost se situent à l'intérieur de l'intervalle de confiance (IC) à 95 % du modèle de Schwartz, ce qui confirme que les deux modèles sont **globalement cohérents** dans leur interprétation du marché en régime normal. XGBoost ne produit donc pas de prédictions aberrantes par rapport au cadre stochastique gaussien.

- **Croix rouges (3 points hors IC)** : les trois points situés hors de l'IC apparaissent tous entre les jours 125 et 170, correspondant aux épisodes de prix extrêmes identifiés précédemment. Ils représentent précisément les situations où XGBoost **détecte la chute des prix** (en prédisant des valeurs faibles), tandis que l'IC du modèle de Schwartz ne descend pas suffisamment bas pour les englober. En effet, la borne inférieure de l'IC de Schwartz reste limitée autour de 3,565, alors que XGBoost prédit des valeurs comprises entre 2,7 et 3,1 durant ces épisodes extrêmes.
- **Interprétation clé** : ces prédictions situées hors de l'IC ne signifient pas que XGBoost est erroné. Au contraire, sur ces trois observations, XGBoost est souvent **plus proche du prix réel** que la borne inférieure de l'IC de Schwartz. Cette situation met en évidence une limite du modèle de Schwartz : son intervalle de confiance est trop étroit dans la partie basse pour couvrir les événements extrêmes, conséquence directe de l'hypothèse de normalité (gaussienne), qui sous-estime la probabilité des queues épaisses, comme l'indique la kurtosis supérieure à 3 observée.



FIGURE 3.10 – Superposition des IC Schwartz et XGBoost et largeur dans le temps.

Ce graphique est le plus riche de l'analyse comparative. Il met en évidence un

arbitrage fondamental entre les deux approches.

Graphique haut : Superposition des IC :

La zone violette (intersection des deux IC) couvre la majorité de la plage de valeurs normales du marché (4.0-5.0), confirmant que les deux modèles sont cohérents en régime normal.

La zone bleue sans vert (IC Schwartz uniquement, en bas vers 3.5-4.0) révèle que Schwartz anticipe des baisses de prix plus profondes que XGBoost ne le prédit, mais ce n'est pas par lucidité : c'est simplement parce que son IC est plus large et s'étend mécaniquement vers le bas.

Les pointes vertes vers le bas (IC XGBoost sortant sous l'IC Schwartz, jours 75, 100, 125, 175) correspondent exactement aux épisodes de prix extrêmes. XGBoost détecte ces épisodes et élargit son IC vers le bas en conséquence, une adaptation dynamique que Schwartz ne peut pas faire. C'est là que XGBoost montre sa vraie valeur ajoutée.

Graphique bas : Largeur des IC dans le temps :

La ligne bleue horizontale (Schwartz, moy=1.726) est quasi-constante sur tout l'horizon, c'est la conséquence directe de la convergence rapide de la variance analytique $\sigma^2/2a$ vers sa valeur asymptotique. Le modèle ne "sait pas" qu'il va se passer quelque chose d'extraordinaire.

La ligne verte (XGBoost, moy=0.769) est en permanence sous la ligne bleue (zone bleue dominante), confirmant que XGBoost est en moyenne 55% plus étroit que Schwartz. Mais elle présente des pics de largeur (jours 10, 25, 100, 125, 175) qui coïncident exactement avec les épisodes de forte volatilité, XGBoost adapte son incertitude au régime de marché.

Une **exception notable** est observée aux alentours du jour 100, où la largeur de l'IC de XGBoost dépasse momentanément celle du modèle de Schwartz (environ 1,8 contre 1,73). Il s'agit du seul instant où l'incertitude estimée par XGBoost est supérieure à celle prédite par le modèle stochastique, ce qui correspond à un épisode marqué de chute des prix.

3.9.2 Discussion

Trois observations ressortent de ce tableau :

1. XGBoost domine en précision ponctuelle : XGBoost réduit la MAE de **18.3%** par rapport à Schwartz (0.241 vs 0.295). Ce gain s'explique par la capacité de XGBoost à exploiter la saisonnalité hebdomadaire (`is_weekend`, `dayofweek`) que Schwartz à tendance constante ignore totalement. LSTM est proche de XGBoost, mais légèrement inférieur, résultat cohérent avec la littérature sur les petits

ensembles de données (~ 700 observations) où le *gradient boosting* surpasse généralement l'apprentissage profond.

2. Schwartz domine en fiabilité de l'IC : Cependant, cet avantage est obtenu au prix d'un IC très large (1.726) et quasi-constant, peu informatif pour un opérateur de marché.

3. Les modèles ML ont un IC sous-calibré : XGBoost (82.8%) présente des couvertures inférieures à 95%. Cela s'explique par la sous-estimation de l'incertitude lors des épisodes extrêmes, les quantile regressions ne capturent pas pleinement la distribution des queues épaisses observées.

3.10 Conclusion

Aucun des trois modèles ne domine sur tous les critères simultanément. Cette observation motive l'approche hybride développée au Chapitre 4 : combiner la décomposition stochastique de Schwartz avec la flexibilité des modèles ML.

CHAPITRE 4

MODÈLE DE SCHWARTZ DEUX FACTEUR

4.1 Motivation et décomposition du log-prix

L'analyse des résidus du modèle un facteur a mis en évidence une non-gaussianité persistante : kurtosis de 28.06, skewness de -3.11 , et rejet systématique des tests de Box-Pierce et Jarque-Bera. Une première piste d'amélioration consiste à enrichir la structure stochastique en introduisant un second facteur de risque, capturant la dynamique long terme du marché.[6]

Le modèle à deux facteurs repose sur une décomposition du log-prix décalé $X_t = \ln(S_t + \text{shift})$ en deux composantes non observables directement :

$$X_t = c_t + l_t \tag{4.1.1}$$

où :

- c_t est la composante court terme : processus d'Ornstein-Uhlenbeck mean-reverting, capturant les chocs transitoires (pics, déséquilibres offre-demande)
- l_t est la composante long terme : marche aléatoire, capturant la tendance structurelle lente du marché (prix du gaz, mix énergétique, développement des renouvelables).

4.2 Dynamiques continues

Sous la probabilité historique $\mathbb{P}$, les dynamiques des deux composantes sont :

$$dc_t = a(m - c_t) dt + \sigma_c dW_t^1 \quad (4.2.1)$$

$$dl_t = -\frac{1}{2}\sigma_l^2 dt + \sigma_l dW_t^2 \quad (4.2.2)$$

avec $\text{Cov}(dW_t^1, dW_t^2) = 0$: les deux sources de bruit sont indépendantes.

4.2.1 Origine du terme $-\frac{1}{2}\sigma_l^2 dt$

Ce terme n'est pas une hypothèse arbitraire : c'est une conséquence directe du lemme d'Itô. Le modèle est initialement formulé sur le prix S_t : sous la probabilité risque-neutre, la composante long terme du prix suit $dS_t^l/S_t^l = \sigma_l dW_t^2$. Le passage au log-prix via $f(S) = \ln(S)$ introduit automatiquement la correction de convexité (inégalité de Jensen, $\mathbb{E}[\ln S] \leq \ln(\mathbb{E}[S])$) :

$$d \ln(S_t^l) = \frac{dS_t^l}{S_t^l} - \frac{1}{2} \frac{d\langle S^l \rangle_t}{(S_t^l)^2} = \sigma_l dW_t^2 - \frac{1}{2}\sigma_l^2 dt \quad (4.2.3)$$

Ce terme est entièrement déterministe et absorbé dans la constante lors de la discrétisation.

4.2.2 Reparamétrage de c_t

La composante court terme est reparamétrée depuis sa forme risque-neutre initiale $dc_t = -\frac{1}{2}\sigma_c^2 dt + \sigma_c dW_t^1$ vers la forme (4.2.1). C'est un simple changement de variable, pas un changement de modèle : la correction d'Itô $-\frac{1}{2}\sigma_c^2 dt$ est absorbée dans la constante m . L'avantage est triple :

- le processus devient stationnaire (retour à la moyenne)
- les paramètres (a, m, σ_c) sont directement interprétables économiquement
- la discrétisation exacte donne un AR(1) calibrable analytiquement.

4.3 Représentation espace d'états

4.3.1 Problème des états cachés

On observe à chaque instant i uniquement la somme $X_i = c_i + l_i$. Les composantes c_i et l_i sont individuellement **non observables**. Il n'est donc pas possible de les estimer séparément par MCO ou EMV sur X_i seul, c'est cette impossibilité qui motive le filtre de Kalman.

4.3.2 Discrétisation exacte

Par intégration des équations (4.2.1) et (4.2.2) sur un intervalle de pas h :

$$c_i = \phi_1 c_{i-1} + \phi_0^c + \varepsilon_i^c, \quad \varepsilon_i^c \sim \mathcal{N}(0, Q_c) \quad (4.3.1)$$

$$l_i = l_{i-1} + \phi_0^l + \varepsilon_i^l, \quad \varepsilon_i^l \sim \mathcal{N}(0, Q_l) \quad (4.3.2)$$

avec :

$$\phi_1 = e^{-ah}, \quad \phi_0^c = m(1 - e^{-ah}), \quad \phi_0^l = -\frac{1}{2}\sigma_l^2 h, \quad Q_c = \sigma_c^2 \frac{1 - e^{-2ah}}{2a}, \quad Q_l = \sigma_l^2 h \quad (4.3.3)$$

Q_c et Q_l sont les variances exactes des bruits d'état — ils représentent l'incertitude intrinsèque sur l'évolution des composantes cachées à chaque pas de temps.

4.3.3 Forme matricielle

Le système s'écrit sous la forme espace d'états standard :

$$\underbrace{\begin{bmatrix} c_i \\ l_i \end{bmatrix}}_{\alpha_i} = \underbrace{\begin{bmatrix} \phi_1 & 0 \\ 0 & 1 \end{bmatrix}}_F \underbrace{\begin{bmatrix} c_{i-1} \\ l_{i-1} \end{bmatrix}}_d + \underbrace{\begin{bmatrix} \phi_0^c \\ \phi_0^l \end{bmatrix}}_d + \begin{bmatrix} \varepsilon_i^c \\ \varepsilon_i^l \end{bmatrix} \quad (4.3.4)$$

$$X_i = \underbrace{\begin{bmatrix} 1 & 1 \end{bmatrix}}_H \begin{bmatrix} c_i \\ l_i \end{bmatrix} + \varepsilon_i^{\text{obs}}, \quad \varepsilon_i^{\text{obs}} \sim \mathcal{N}(0, R) \quad (4.3.5)$$

Justification de chaque terme.

- $F_{11} = \phi_1 = e^{-ah} < 1$: coefficient AR(1) de c_t . Comme $a > 0$, on a $\phi_1 \in (0, 1)$, c_t est stationnaire avec retour à la moyenne en demi-vie $\tau_{1/2} = \ln(2)/a$.
- $F_{22} = 1$: coefficient unitaire pour l_t . Aucune force de rappel, l_t est une marche aléatoire qui dérive lentement dans le temps sans retour à la moyenne.
- $F_{12} = F_{21} = 0$: termes nuls car les deux composantes évoluent indépendamment par hypothèse ($\text{Cov}(dW_t^1, dW_t^2) = 0$). Cette hypothèse est vérifiée empiriquement sur les données réelles ($\text{Corr}(\hat{c}_t, \hat{l}_t) = 0.097 \approx 0$, voir Section 4.6.4).
- $H = [1, 1]$: on observe la somme $X_i = c_i + l_i$, jamais les composantes séparément. H traduit simplement cette relation de mesure.

- $R \approx 0$ ($R = 10^{-4}$) : les prix spot sont cotés sur un marché organisé sans erreur de mesure, contrairement à des données physiques (position d'un satellite, signal radar). On pose une valeur petite mais strictement positive pour des raisons de stabilité numérique lors des inversions de matrices.
- $Q = \text{diag}(Q_c, Q_l)$: matrice diagonale car les deux bruits sont indépendants. Q représente l'**incertitude sur le modèle** lui-même, plus Q est grand, plus le filtre fera confiance aux observations plutôt qu'aux prédictions du modèle.

4.4 Le filtre de Kalman

4.4.1 Principe général

Le filtre de Kalman [3] est l'estimateur linéaire **optimal** au sens de l'erreur quadratique minimale pour les systèmes espace d'états gaussiens. À chaque pas de temps i , il alterne deux étapes :

- **Prédiction** : estimer l'état en i à partir du modèle dynamique et de l'état estimé en $i - 1$, *avant* d'observer X_i ;
- **Mise à jour** : corriger cette prédiction en intégrant l'information de X_i .

En sortie de chaque itération, l'état filtré $\hat{\alpha}_{i|i} = [\hat{c}_i, \hat{l}_i]^T$ est la meilleure estimation des composantes cachées conditionnellement à toutes les observations jusqu'en i .

4.4.2 Équations détaillées

Notons $\hat{\alpha}_{i|j}$ l'estimation de l'état en i sachant les observations jusqu'en j , et $P_{i|j}$ la matrice de covariance associée (incertitude sur l'estimation).

Étape 1 : Prédiction.

$$\hat{\alpha}_{i|i-1} = F\hat{\alpha}_{i-1|i-1} + d \quad (4.4.1)$$

$$P_{i|i-1} = FP_{i-1|i-1}F^T + Q \quad (4.4.2)$$

On applique le modèle dynamique à l'état estimé précédent. La covariance augmente d'un terme Q : en l'absence de nouvelle observation, l'incertitude grandit car le bruit d'état η_i a été ajouté.

Étape 2 : Innovation.

$$v_i = X_i - H\hat{\alpha}_{i|i-1} \quad (4.4.3)$$

$$S_i = HP_{i|i-1}H^T + R \quad (4.4.4)$$

v_i est l'écart entre le prix *observé* X_i et le prix *prédit* $H\hat{\alpha}_{i|i-1} = \hat{c}_{i|i-1} + \hat{l}_{i|i-1}$. Si $v_i = 0$, la prédiction était parfaite. S_i est la variance de cette erreur de prédiction.

Étape 3 : Gain de Kalman.

$$K_i = P_{i|i-1}H^TS_i^{-1} \quad (4.4.5)$$

$K_i \in \mathbb{R}^2$ est le vecteur de pondération arbitrant entre le modèle et l'observation :

- si Q est grand (modèle incertain) $\Rightarrow P_{i|i-1}$ grand $\Rightarrow K_i$ grand $\Rightarrow$ l'observation est prépondérante ;
- si R est grand (observation bruitée) $\Rightarrow S_i$ grand $\Rightarrow K_i$ petit $\Rightarrow$ le modèle est prépondérant ;
- dans notre cas $R \approx 0$, le filtre accorde une large confiance aux observations.

Étape 4 : Mise à jour.

$$\hat{\alpha}_{i|i} = \hat{\alpha}_{i|i-1} + K_iv_i \quad (4.4.6)$$

$$P_{i|i} = (I - K_iH)P_{i|i-1} \quad (4.4.7)$$

L'état est corrigé proportionnellement à l'innovation, pondérée par K_i . La covariance diminue : avoir observé X_i réduit l'incertitude sur $[\hat{c}_i, \hat{l}_i]$.

Log-vraisemblance des innovations : La calibration des paramètres $\theta = (a, m, \sigma_c, \sigma_l)$ se fait par maximisation de :

$$\mathcal{L}(\theta) = -\frac{1}{2} \sum_{i=1}^n \left[\ln(S_i) + \frac{v_i^2}{S_i} \right] \quad (4.4.8)$$

via l'algorithme de Nelder-Mead, initialisé à partir des paramètres MCO du modèle un facteur : $\theta_0 = (a_{1F}, m_{1F}, 0.7\sigma_{1F}, 0.3\sigma_{1F})$.

4.4.3 Remarque sur la distinction données simulées/réelles

Cette distinction est fondamentale :

- **Données simulées :** on génère soi-même c_i et l_i par récurrence, les « vraies » valeurs sont connues. Le graphique « c_t vraie vs $\hat{c}_t$ filtrée » mesure directement la qualité de reconstruction du filtre.

- **Données réelles** : c_t et l_t sont fondamentalement **non observables**. Il n'existe aucune vraie valeur de référence. On affiche uniquement $\hat{c}_t$ et $\hat{l}_t$ — les meilleures estimations produites par le filtre après mise à jour.

4.5 Simulation de validation

4.5.1 Protocole

On fixe des paramètres vrais en unités annuelles ($h = 1/365$) :

$$a = 150 \text{ ans}^{-1}, \quad m = 3.5, \quad \sigma_c = 0.8, \quad \sigma_l = 0.3 \quad (4.5.1)$$

On simule $n = 730$ jours par récurrence ; le filtre ne voit que $X_i = c_i + l_i$, jamais c_i ni l_i séparément. La Figure 4.1 montre les trajectoires simulées des trois séries.




FIGURE 4.1 – Trajectoires simulées du modèle deux facteurs : log-prix $X_t = c_t + l_t$

4.5.2 Reconstruction des composantes




FIGURE 4.2 – Reconstruction des composantes par le filtre de Kalman sur données simulées.

La Figure 4.2 présente la reconstruction obtenue avec les vrais paramètres. Le filtre converge rapidement et restitue fidèlement les deux dynamiques :

- c_t : fluctuations rapides autour de $m = 3.5$ bien reconstituées, avec une légère atténuation des pics extrêmes, comportement attendu du filtre qui lisse l'incertitude.
- l_t : tendance lente (marche aléatoire) parfaitement reconstituée.
- RMSE de reconstruction : 0.033 pour les deux composantes.

4.5.3 Résultats de calibration

TABLE 4.1 – Calibration du modèle deux facteurs sur données simulées

Paramètre	Vraie valeur	Estimée (EMV)	Écart relatif (%)
a (ans ⁻¹)	150.0	115.277	23.1
m	3.5	3.435	1.9
σ_c	0.8	0.708	11.5
σ_l	0.3	0.248	17.5

Les volatilités σ_c et σ_l sont estimées avec des écarts relatifs de 11.5% et 17.5% respectivement comparables aux performances du modèle un facteur en simulation. L'écart plus élevé sur a (23.1%) est attendu : avec $h = 1/365$, la demi-vie de c_t est de ~ 1.7 jours, à la limite de la résolution temporelle des données journalières.

Lors des tests de simulation, on a observé des difficultés d'identification lorsque a est trop petit (typiquement $a < 10$ ans⁻¹) : les dynamiques de c_t et l_t deviennent trop similaires pour être distinguées à partir de leur seule somme. Dans notre cas, la composante court terme est suffisamment rapide pour être distinguée de la composante long terme par le filtre de Kalman.

4.6 Calibration sur données réelles

4.6.1 Paramètres estimés

La calibration est réalisée sur le train set ($h = 1$ jour) :

TABLE 4.2 – Paramètres calibrés du modèle deux facteurs sur données réelles

Paramètre	Valeur estimée	Interprétation
a (jours ⁻¹)	1.0224	Vitesse retour à la moyenne c_t
σ_c	0.5737	Volatilité court terme
σ_l	0.0228	Volatilité long terme
Demi-vie c_t	0.68 jour	$\ln(2)/a$
Condition initiale a_0	0.76	Issu du modèle 1F (MCO)

La demi-vie de c_t de **0.68 jour** confirme que la composante court terme capture des chocs résorbés en moins d’une journée, caractéristique du marché électrique spot.

4.6.2 Décomposition des facteurs filtrés




FIGURE 4.3 – Décomposition du log-prix par le filtre de Kalman sur données réelles.

$\hat{c}_t$ (court terme) : Fluctuations rapides autour du niveau moyen, avec des chutes brutales correspondant aux épisodes de prix très bas (surplus renouvelable, mai–juin 2025). Le retour à la moyenne est visible : les déviations sont résorbées en ~ 1 jour.

$\hat{l}_t$ (**long terme**) : Évolution lente et quasi-monotone, capturant la tendance structurelle du marché. Radicalement différente de $\hat{c}_t$, aucun retour à la moyenne.

4.6.3 Décomposition de la variance




FIGURE 4.4 – Décomposition de la variance entre les deux composantes filtrées.

TABLE 4.3 – Décomposition de la variance du log-prix entre les deux composantes

Composante	Variance	Part (%)
$\hat{c}_t$ (court terme)	0.1477	81.2
$\hat{l}_t$ (long terme)	0.0341	18.8
X_t total	0.1958	—

La composante court terme domine avec 81.2% de la variance totale, cohérent avec la nature du marché électrique spot, piloté principalement par des chocs de court terme.

La composante long terme $\hat{l}_t$ n'explique que 18.8% de la variance totale (0.0341/0.1958). Elle représente la tendance structurelle lente du marché, liée aux fondamentaux (mix énergétique, prix du gaz, développement des renouvelables).

Ce résultat est cohérent avec la nature du marché électrique spot : les prix sont essentiellement pilotés par des chocs de très court terme (déséquilibres offre-demande

instantanés, aléas météorologiques, incidents de production) plutôt que par des tendances de fond. Il justifie a posteriori l'utilisation d'un modèle *mean-reverting* rapide pour c_t et d'une marche aléatoire lente pour l_t .

La somme des parts individuelles ($75.4\% + 17.4\% = 92.8\%$) est inférieure à 100% : l'écart de 7.2% correspond au terme croisé $2 \text{Cov}(\hat{c}_t, \hat{l}_t)$, non nul en pratique malgré l'hypothèse théorique d'indépendance.

Cela signifie que les prix spot sont principalement dominés par des chocs de court terme. Cette répartition est caractéristique du marché de l'électricité, où les fluctuations rapides sont liées aux pics de consommation, aux aléas de production et aux contraintes du réseau.

4.6.4 Indépendance empirique des composantes




FIGURE 4.5 – Nuage de points $(\hat{c}_t, \hat{l}_t)$ sur l'ensemble d'entraînement.

La Figure 4.5 présente le nuage de points $(\hat{c}_t, \hat{l}_t)$. La corrélation empirique est :

$$\text{Corr}(\hat{c}_t, \hat{l}_t) = 0.097 \approx 0 \quad (4.6.1)$$

Cette valeur très proche de zéro valide empiriquement l'hypothèse d'indépendance $\text{Cov}(dW_t^1, dW_t^2) = 0$.

- La grande majorité des observations est concentrée dans la zone $\hat{c}_t \in [3.2, 4.5]$ et $\hat{l}_t \in [0.4, 1.0]$, le régime "normal" du marché.
- Les points isolés à gauche ($\hat{c}_t < 2$) correspondent aux épisodes de prix extrêmement bas (surproduction renouvelable), où $\hat{c}_t$ chute brutalement sans

que $\hat{l}_t$ soit affecté, preuve que les deux dynamiques sont bien découplées en régime extrême.

l'hypothèse d'indépendance est empiriquement vérifiée sur les données, ce qui renforce la validité du modèle deux facteurs sur ce marché.

4.6.5 Contribution aux pics de prix




FIGURE 4.6 – Contribution des composantes filtrées lors des pics de prix (seuil $\mu + 2\sigma = 5.32$, points rouges).

La Figure 4.6 identifie 4 pics dépassant le seuil $\mu + 2\sigma = 5.32$ (en log-prix), tous concentrés en décembre 2024 – janvier 2025.

TABLE 4.4 – Valeurs moyennes des composantes lors des pics vs hors pics

Composante	Lors des pics	Hors pics	Variation
$\hat{c}_t$	4.605	3.800	+21.2%
$\hat{l}_t$	0.941	0.627	+50.1%

$\hat{c}_t$ est significativement plus élevé lors des pics (+21.2%), confirmant son rôle de capteur des chocs de court terme. La hausse de $\hat{l}_t$ (+50.1%) s'explique par la concentration des pics en période hivernale, où la tendance long terme est structurellement haute.

4.6.6 Comparaison des résidus : un facteur vs deux facteurs




FIGURE 4.7 – Comparaison des distributions des résidus/innovations face à la loi normale théorique.

Le modèle deux facteurs sépare mieux les dynamiques (court terme, long terme) mais utilise toujours des bruits gaussiens. Il ne peut donc pas capturer les queues épaisses, c'est une limite structurelle des deux modèles.

TABLE 4.5 – Tests statistiques sur les résidus

Modèle	Skewness	Kurtosis	JB p-value	BP p-value
Schwartz 1 facteur (MCO)	-3.112	28.061	0.0	0.0
Schwartz 2 facteurs (Kalman)	-3.168	27.854	0.0	0.0

Les deux modèles rejettent l'hypothèse de bruit blanc gaussien avec des valeurs quasi-identiques. Le kurtosis passe de 28.06 à 27.85, soit une réduction de seulement **0.7%**. Ce résultat est une conclusion scientifique importante : l'ajout d'un second facteur gaussien n'améliore pas la gaussianité des innovations. La non-normalité est *intrinsèque aux données*, elle reflète les pics de prix, les prix négatifs et les sauts discontinus du marché électrique, qui ne peuvent pas être capturés par une somme de bruits gaussiens, quel que soit leur nombre. Seules des lois à queues épaisses [1] ou des approches non paramétriques (*Machine Learning*) peuvent résoudre ce problème structurel.

4.7 Approches hybrides

Malgré l'amélioration apportée par la représentation à deux facteurs et l'estimation des composantes latentes par le filtre de Kalman, le modèle reste fondé sur des hypothèses paramétriques et gaussiennes qui peuvent limiter sa capacité à reproduire certaines caractéristiques des prix réels, notamment les comportements non linéaires et les épisodes extrêmes. Ces limites motivent l'utilisation d'une approche hybride combinant la structure stochastique du modèle avec la flexibilité des méthodes de Machine Learning.

4.7.1 Principe et motivation

Plutôt que de traiter Schwartz et ML comme deux approches séparées, on propose de les combiner : la décomposition stochastique du filtre de Kalman alimente des modèles ML spécialisés, dont les prédictions sont ensuite recombinaées :

$$\hat{X}_{t+1} = \hat{c}_{t+1}^{\text{ML}} + \hat{l}_{t+1}^{\text{ML}} \quad (4.7.1)$$

L'hypothèse est que chaque modèle ML apprend une dynamique plus simple et mieux structurée que X_t brut :

- ML_c : features de court terme (lags $\{1, 2, 3\}$, variables calendaires, écart à la moyenne sur 7 jours)
- ML_l : features de long terme (lags $\{1, 3, 7, 14\}$, moyennes glissantes sur 7 et 14 jours, indicateur de tendance).

4.7.2 XGBoost hybride



FIGURE 4.8 – Prédictions du modèle XGBoost par composante sur l'ensemble de test.

La Figure 4.8 présente les prédictions par composante et la recombinaison finale.

TABLE 4.6 – Performances du XGBoost hybride vs classique

Modèle	MAE	RMSE	Couverture IC 95%	Largeur IC
XGBoost classique	0.2410	0.3569	82.8%	0.769
XGBoost hybride	0.2101	0.3335	94.4%	0.998
Amélioration	-12.8%	-6.5%	+11.6 pts	—




FIGURE 4.9 – Comparaison des intervalles de confiance à 95% sur l'ensemble de test.

La décomposition Kalman améliore XGBoost de **12.8% en MAE** et porte la couverture de l'IC de 82.8% à **94.4%**, très proche de la cible théorique de 95%. La Figure 4.9 compare visuellement les IC de Schwartz et du modèle hybride XGBoost sur le test set.

4.7.3 LSTM hybride

Même logique que l'XGBoost hybride : au lieu de prédire X_t directement, on entraîne deux LSTM spécialisés sur les composantes identifiées par le filtre de Kalman, puis on recombine :

$$\hat{X}_{t+1} = \text{LSTM}_c(\hat{c}_{t-6}, \dots, \hat{c}_t) + \text{LSTM}_l(\hat{l}_{t-6}, \dots, \hat{l}_t)$$

Hypothèse : chaque LSTM apprend une dynamique plus simple et plus structurée, LSTM_c apprend le retour à la moyenne rapide, LSTM_l apprend la tendance lente.

Note sur T : on conserve T=7 jours validé empiriquement, mais on laisse la possibilité que les deux composantes aient des T optimaux différents, $\hat{l}_t$ étant plus

lente, un T plus long pourrait être bénéfique.

La même architecture LSTM (deux couches $64 \rightarrow 32$, *Dropout* 0.2, $T = 7$) est entraînée séparément sur $\hat{c}_t$ et $\hat{l}_t$.




FIGURE 4.10 – Modèle LSTM sur les composantes prédit par le filtre de Kalman

Résultat remarquable sur l_t : Le LSTM spécialisé sur la composante long terme atteint une MAE de 0.029, quasi-parfaite. La composante $\hat{l}_t$ étant une marche aléatoire à faible volatilité ($\sigma_l = 0.023$), la prédiction $\hat{l}_{t+1} \approx \hat{l}_t$ est déjà très précise sur une fenêtre de 7 jours, et le LSTM apprend cette persistance sans difficulté.




FIGURE 4.11 – Intervalle de confiance généré

TABLE 4.7 – Performances du LSTM hybride vs classique

Modèle	MAE	RMSE	Couverture IC 95%	Largeur IC
LSTM classique	0.2694	0.3680	97.0%	1.400
LSTM hybride	0.2310	0.3587	90.0%	0.870
Amélioration MAE	−14.2%	−2.5%		

La décomposition Kalman améliore le LSTM de 14.2% en MAE et 2.5% en RMSE, un gain comparable à celui observé pour XGBoost(−12.8% en MAE). Ce résultat confirme que l’apport de la décomposition stochastique est robuste au choix du modèle ML : qu’on utilise XGBoost ou LSTM, spécialiser chaque modèle sur une dynamique bien définie améliore systématiquement les performances.

L’IC à 95% du LSTM hybride (couverture=90.0%, largeur=0.870) présente une sous-couverture par rapport à la cible théorique de 95%. Cette limitation s’explique par la méthode de construction de l’IC hybride : le Monte Carlo *Dropout* appliqué séparément sur LSTM_c et LSTM_l ignore la covariance entre les deux sources d’incertitude lors de la sommation :

$$\text{Var}[\hat{c}_t + \hat{l}_t] = \text{Var}[\hat{c}_t] + \text{Var}[\hat{l}_t] + \underbrace{2\text{Cov}[\hat{c}_t, \hat{l}_t]}_{\text{ignoré}}$$

Cette approximation conduit à sous-estimer la largeur de l’IC et donc à une couverture empirique inférieure à 95%. Une correction possible serait de construire l’IC directement sur les prédictions recombinaées $\hat{X}_t = \hat{c}_t + \hat{l}_t$, plutôt que de sommer les IC individuels.

4.7.4 Apport systématique de la décomposition Kalman

TABLE 4.8 – Gain en MAE apporté par la décomposition Kalman selon le modèle

Modèle ML	MAE classique	MAE hybride	Gain
XGBoost	0.2410	0.2101	−12.8%
LSTM	0.2694	0.2310	−14.2%

Quel que soit le modèle ML utilisé, la décomposition en $\hat{c}_t$ et $\hat{l}_t$ améliore significativement les performances. Ce résultat valide l’hypothèse centrale de ce travail : la décomposition stochastique de Schwartz apporte une information structurante que les modèles ML ne peuvent pas extraire directement depuis le log-prix brut X_t .

4.8 Conclusion

Ce chapitre a permis d'étendre la modélisation stochastique à un modèle de Schwartz à deux facteurs, permettant de distinguer les dynamiques de court et de long terme des prix spot. L'utilisation du filtre de Kalman a ensuite permis d'estimer les composantes non observables du modèle à partir des données disponibles. Sur cette base, des approches hybrides combinant la décomposition stochastique avec les modèles d'apprentissage automatique ont été développées afin de tirer parti des avantages complémentaires des deux approches. Les résultats obtenus montrent l'intérêt de cette combinaison pour améliorer les performances de prévision et la quantification de l'incertitude. Le chapitre suivant présente une comparaison globale des différentes approches afin d'en évaluer les performances et les limites respectives.

CHAPITRE 5

DISCUSSION ET COMPARAISON FINALE

5.1 Métriques d'évaluation utilisées

L'évaluation des modèles repose sur deux familles de métriques complémentaires, appliquées sur le même ensemble de test.

5.1.1 Métriques de précision ponctuelle

Erreur absolue moyenne (MAE).

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |X_i - \hat{X}_i| \quad (5.1.1)$$

La MAE mesure l'erreur moyenne en valeur absolue. Elle est robuste aux valeurs extrêmes, un pic de prix isolé pénalise la MAE linéairement, sans dominer le résultat comme le ferait une erreur quadratique. C'est pourquoi elle est retenue comme métrique principale dans ce travail, en cohérence avec la fonction de perte utilisée pour entraîner le LSTM (`nn.L1Loss`).

Racine de l'erreur quadratique moyenne (RMSE).

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \hat{X}_i)^2} \quad (5.1.2)$$

Le RMSE pénalise davantage les grandes erreurs. Il est complémentaire à la MAE : un écart important entre RMSE et MAE indique la présence d'erreurs extrêmes ponctuelles. Les deux métriques sont calculées dans l'espace du log-prix décalé $X_t = \ln(S_t + \text{shift})$ pour garantir la comparabilité entre modèles.

5.1.2 Métriques de qualité des intervalles de confiance

Couverture empirique : Proportion d’observations réelles tombant dans l’IC à 95% :

$$\text{Couverture} = \frac{1}{n} \sum_{i=1}^n \mathbf{1} [X_i \in [\hat{X}_i^{2.5\%}, \hat{X}_i^{97.5\%}]] \quad (5.1.3)$$

Un IC bien calibré doit afficher une couverture proche de 95%.

Largeur moyenne : $\bar{L} = \frac{1}{n} \sum_{i=1}^n (\hat{X}_i^{97.5\%} - \hat{X}_i^{2.5\%})$. Entre deux modèles à couverture comparable, celui avec la largeur la plus faible est le plus informatif.

5.2 Comparaison finale des modèles

5.2.1 Tableau récapitulatif

TABLE 5.1 – Comparaison finale des six modèles sur l’ensemble de test journalier

Modèle	MAE	RMSE	IC 95% couv.	IC 95% larg.
Schwartz 1 facteur	0.2948	0.3840	98.3%	1.726
XGBoost classique	0.2410	0.3569	82.8%	0.769
XGBoost hybride	0.2101	0.3335	94.4%	0.998
LSTM classique	0.2490	0.3653	86.8%	0.795
LSTM hybride	0.2310	0.3587	90.0%	0.870

5.2.2 Analyse par critère

Précision ponctuelle : L’XGBoost hybride domine tous les modèles avec une amélioration de 28.7% par rapport à Schwartz et de 12.8% par rapport à XGBoost classique. La décomposition Kalman améliore systématiquement les deux modèles ML : −12.8% pour XGBoost, −14.2% pour LSTM, indépendamment du modèle utilisé.

Qualité des intervalles de confiance : Aucun modèle ne domine sur les deux critères simultanément : XGBoost hybride : meilleur compromis, couverture 94.4% (proche de la cible 95%) et largeur 0.998 (−42% vs Schwartz).

Modèle deux facteurs : Le passage du modèle un facteur au modèle deux facteurs n’améliore pas significativement la gaussianité des résidu. Ce résultat confirme que la non-normalité est **intrinsèque aux données**, elle reflète les pics de prix, les prix négatifs et les sauts discontinus que ne peut pas capturer une somme de bruits gaussiens, quel que soit leur nombre.

5.3 Extension aux données horaires

5.3.1 Motivation

Les modèles journaliers souffrent d’une limite structurelle : le LSTM est entraîné sur seulement **905 observations**, ce qui est insuffisant pour exprimer pleinement sa capacité de mémorisation séquentielle. Pour tester l’hypothèse que le LSTM bénéficie d’un plus grand dataset, les modèles XGBoost et LSTM ont été ré-entraînés directement sur les données horaires brutes (21 700 observations).

5.3.2 Résultats

TABLE 5.2 – Impact de la résolution temporelle sur les performances ML

Modèle	Obs.	MAE	RMSE	IC couv.
XGBoost journalier	~905	0.2410	0.3569	82.8%
LSTM journalier	~905	0.2690	0.38	97.1%
XGBoost horaire	~21 700	0.0166	0.0989	92.6%

5.3.3 Discussion

Deux conclusions ressortent de cette extension :

1. Impact de la résolution sur le LSTM : Le passage aux données horaires modifie fondamentalement la nature de la tâche de prédiction. En journalier, l’agrégation des 24 heures **lisse les pics** et réduit la variance du signal, le LSTM apprend un signal plus régulier et plus prévisible. En horaire, chaque observation est brute, avec tous les pics, les chutes brutales et les prix négatifs. La difficulté intrinsèque de la tâche augmente fortement, ce qui peut contrebalancer l’avantage du volume de données.

2. Avantage structurel de XGBoost sur données horaires : XGBoost exploite des features explicites adaptées à la résolution horaire (`hour_sin`, `hour_cos`, `is_weekend`, lags horaires) qui capturent directement la double crête journalière (pic à 8h, creux à 13h, pic à 20h) identifiée lors de l’analyse exploratoire. Ces features permettent à XGBoost de reproduire fidèlement le profil journalier typique sans nécessiter la mémoire séquentielle du LSTM.

5.3.4 Prédiction heure par heure

À titre d’illustration, une prédiction des 24 heures du lendemain (2026-06-24) est réalisée avec les deux modèles horaires. La Figure 5.1 présente le profil horaire prédit.




FIGURE 5.1 – Prédiction XGBoost horaire.

La prédiction XGBoost reproduit fidèlement le **profil en double crête** caractéristique du marché électrique néerlandais identifié lors de l’analyse exploratoire : creux nocturne, pic matinal lié à la reprise industrielle, creux de mi-journée dû à la production solaire, et pic du soir correspondant à la reprise de consommation après le travail. Cette cohérence avec les patterns empiriques conforte la pertinence du *feature engineering* retenu.

5.4 Limites du travail

- Données journalières pour les modèles stochastiques :** le modèle de Schwartz est calibré sur données journalières ($h = 1$ jour), perdant toute l’in-

formation intra-journalière. Une calibration sur données horaires nécessiterait d'adapter le modèle à tendance variable avec une courbe forward complète.

2. **Absence de variables exogènes** : les modèles ML n'utilisent que les prix passés. L'intégration de variables physiques (production éolienne, consommation, échanges transfrontaliers) améliorerait significativement les performances.
3. **Modèle à tendance constante uniquement** : le modèle de Schwartz à tendance variable (qui intègre la saisonnalité via la courbe forward) n'a pas été implémenté faute de données forward disponible pour le marché néerlandais.
4. **Asymétrie méthodologique** : Schwartz réalise des prédictions *multi-step* depuis le dernier point de l'ensemble d'entraînement, tandis que les modèles ML font des prédictions à un pas exploitant les vraies valeurs passées. Cette asymétrie favorise structurellement les modèles ML sur la métrique MAE.
5. **Taille du dataset pour le LSTM** : sur données journalières (~ 905 observations), le LSTM opère en dessous de son régime optimal. L'extension aux données horaires ($\sim 21\,700$ observations) améliore les performances mais au prix d'une tâche de prédiction plus difficile.

CONCLUSION GÉNÉRALE

Ce travail de recherche avait pour objectif de développer et d'évaluer différentes approches de modélisation des prix spot de l'électricité sur le marché néerlandais, en confrontant les modèles stochastiques de Schwartz aux méthodes modernes de Machine Learning. Cette étude répond à un enjeu majeur du secteur énergétique, où la forte volatilité des prix, l'apparition de prix négatifs et l'intégration croissante des énergies renouvelables rendent la prévision particulièrement complexe.

L'analyse exploratoire des données a mis en évidence les principales caractéristiques du marché électrique : une saisonnalité marquée à plusieurs échelles temporelles, un phénomène de retour à la moyenne, une hétéroscédasticité importante ainsi que la présence fréquente de pics de prix et de valeurs négatives. Ces propriétés montrent que les hypothèses gaussiennes classiques restent insuffisantes pour décrire fidèlement la dynamique réelle des prix.

Dans un premier temps, le modèle de Schwartz à un facteur a été implémenté, calibré puis validé sur des données simulées et réelles. Les estimations obtenues par les méthodes des moindres carrés et du maximum de vraisemblance se sont révélées cohérentes avec les résultats théoriques. En revanche, l'analyse des résidus a confirmé que les hypothèses de normalité et d'indépendance ne sont pas vérifiées sur les données réelles, ce qui limite les performances prédictives de cette approche malgré la qualité de ses intervalles de confiance.

Le modèle de Schwartz à deux facteurs, estimé à l'aide du filtre de Kalman, a permis de séparer les dynamiques de court et de long terme présentes dans les prix. Cette décomposition fournit une représentation plus riche du processus sous-jacent, mais elle ne suffit pas à résoudre la non-gaussianité des données. Les résidus conservent des queues épaisses et des comportements extrêmes, ce qui montre que l'ajout d'un second facteur gaussien ne permet pas, à lui seul, de reproduire toute la complexité du marché électrique.

Les modèles d'apprentissage automatique, et plus particulièrement XGBoost et

LSTM, ont ensuite démontré leur capacité à mieux capturer les comportements non linéaires et les dépendances temporelles, améliorant sensiblement la précision des prévisions ponctuelles. Néanmoins, leurs méthodes d'estimation de l'incertitude restent imparfaitement calibrées lors des épisodes de forte volatilité.

La principale contribution de ce travail réside dans le développement d'une approche hybride combinant les deux familles de méthodes. En exploitant la décomposition obtenue par le filtre de Kalman comme étape de prétraitement avant l'apprentissage, les modèles hybrides bénéficient simultanément de l'interprétabilité offerte par la modélisation stochastique et de la capacité d'adaptation des méthodes d'apprentissage automatique. Les résultats expérimentaux montrent que cette stratégie améliore systématiquement les performances des modèles d'apprentissage automatique, l'approche XGBoost hybride offrant le meilleur compromis entre précision des prévisions et qualité des intervalles de confiance. Cette observation suggère que les modèles stochastiques et les méthodes d'intelligence artificielle doivent être considérés comme complémentaires plutôt que concurrents.

Enfin, plusieurs perspectives peuvent prolonger ce travail. L'intégration de variables exogènes telles que la production renouvelable, la consommation électrique, les conditions météorologiques ou les échanges transfrontaliers pourrait encore améliorer les performances prédictives. D'un point de vue probabiliste, l'utilisation de modèles à queues épaisses ou de processus à sauts constituerait une alternative pertinente pour mieux représenter les événements extrêmes observés sur les marchés électriques. Enfin, l'extension de cette méthodologie à des prévisions horaires ou multi-horizons ainsi qu'à d'autres marchés européens permettrait d'évaluer la robustesse et la généralisabilité de l'approche proposée.

En définitive, ce travail montre que la combinaison des modèles stochastiques et des méthodes d'apprentissage automatique constitue une voie particulièrement prometteuse pour la prévision des prix de l'électricité. Elle permet de tirer parti des fondements théoriques des modèles probabilistes tout en bénéficiant de la puissance d'apprentissage des approches modernes, ouvrant ainsi des perspectives intéressantes pour la recherche comme pour les applications opérationnelles dans les marchés de l'énergie.

- [1] Senhadji El Rhazi, O. *Modélisation et calibration des prix spot électriques*, Thèse de Master de Probabilités et Finance, Université Paris VI, 2004.
- [2] Eduardo S. Schwartz *The Stochastic Behavior of Commodity Prices : Implications for Valuation and Hedging*, The Journal of Finance, 52(3), 923–973, 1997.
- [3] Rudolf E. Kalman *A New Approach to Linear Filtering and Prediction Problems*, Transactions of the ASME — Journal of Basic Engineering, 82(Series D), 35–45, 1960.
- [4] Sepp Hochreiter, Jürgen Schmidhuber *Long Short-Term Memory*, Neural Computation, 9(8), 1735–1780, 1997.
- [5] Tianqi Chen, Carlos Guestrin *XGBoost : A Scalable Tree Boosting System*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794, 2016.
- [6] Philipp Erb, David Lüthi, Simon Ötziger *Schwartz 1997 Two-Factor Model : Technical Document*, ETH Zürich, 2014.
- [7] Maria Tzelepi, Charalampos Symeonidis *Deep Learning for Energy Time-Series Analysis and Forecasting*, arXiv preprint arXiv :2306.09129, 2023.
- [8] Michael Orlitzky *Ornstein-Uhlenbeck Processes*, Lecture Notes, Towson University, 2013.